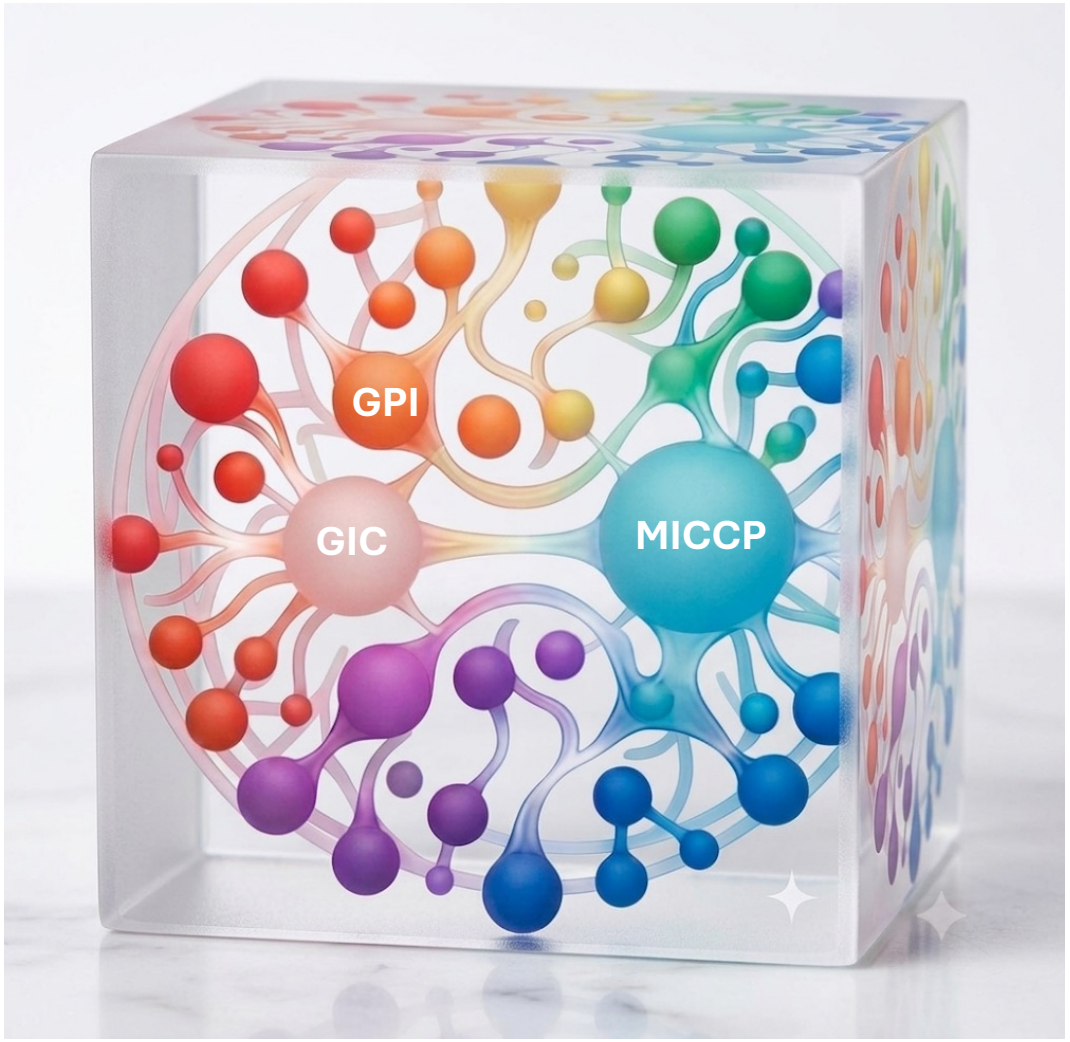


Proyecto de Integración de Bloques de Cálculo – con la Ayuda de los Modelos de Lenguaje de Inteligencia Artificial - en el Aprendizaje de Ingeniería Civil

ProfesIA

Sesión	Tema	Duración
1	Presentación	1.5 h
2	VSCode + Python + GitHub Copilot (1)	1 h
3	VSCode + Python + GitHub Copilot (2)	1 h
4	VSCode + Python + GitHub Copilot (3)	1 h
5	VSCode + Python + GitHub Copilot (4)	1 h
6	VSCode + Python + GitHub Copilot (5)	1 h
7	Gráficos vectoriales SVG	1 h
8	Markdown – Quarto	1 h
9	VSCode + QGIS	1 h
10	VSCode + CAD + BIM	1 h
11	IA como asistente	1 h
12	IAs locales (1)	1 h
13	IAs locales (2)	1 h
14	Agentes IA – IA agéntica	1 h


Primeros Ejemplos

Objetivos (I)

- Aprovechar las bondades de la IA para mejorar las capacidades de nuestros alumnos (y de los profesores)
- Utilizar un lenguaje intermedio de comunicación con la IA – Ecosistema de Notebooks de Programación
- Hacer un repositorio de Bloques Unitarios (minijobs, procesos de cálculo) en la Escuela
- Resolver problemas de ingeniería a través de modelos de agregación de bloques – diagramas de flujo o pipelines / procesos iterativos

Objetivos (II)

- Plasmarlo en varios proyectos de *(innovación docente)* Escuela

  - Proyecto Nivel 1: Bloques básicos de materias de Matemáticas/Física/Dibujo
  - Proyectos Nivel 2: Asignaturas tecnológicas: Bloques Básicos + Metodologías
  - Proyectos Nivel 3: – Inter-asignatura - Integración de bloques de Metodologías
    - Proyecto 1: Puente (Geotecnia+Estructuras+Construcción)
    - Proyecto 2: Inundación en ciudad (Estadística+Geomática+Hidrología+Hidráulica)
    - Proyecto 3: Ciudad (Urbanismo+Transporte+…)
    - Proyecto 4: Carretera (Geomática+Caminos+Hidrología+Construcción)
    - …

- Aprovechar este marco para formentar sinergías entre los distintos grupos de las Escuela

- Construir una IA local (open source) **IA.Caminos.Santander**, integrando Bloques, Metodologías, Manuales

Nivel 1: Bloques Materias Básicas + Bloques Materias Tecnológicas



Nivel 2: Metodologías en Materias Tecnológicas

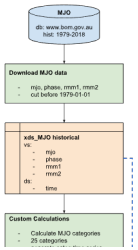


Nivel 3: Proyectos Inter-asignaturas



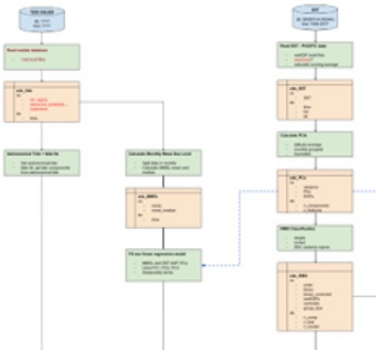
Nivel 1:
bloque





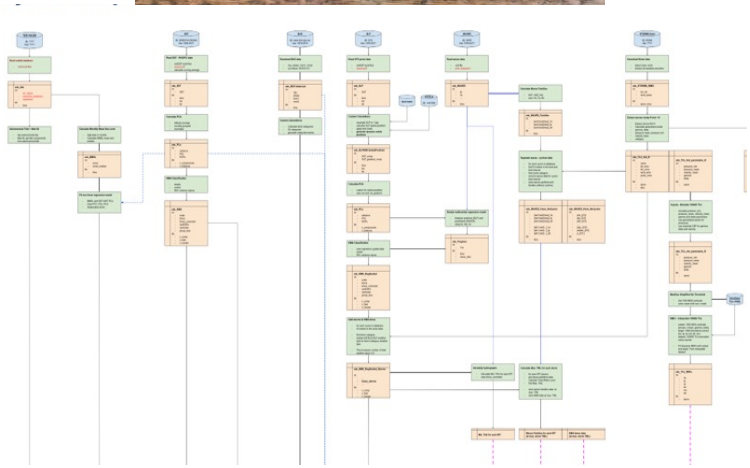
Nivel 2:
metodologías





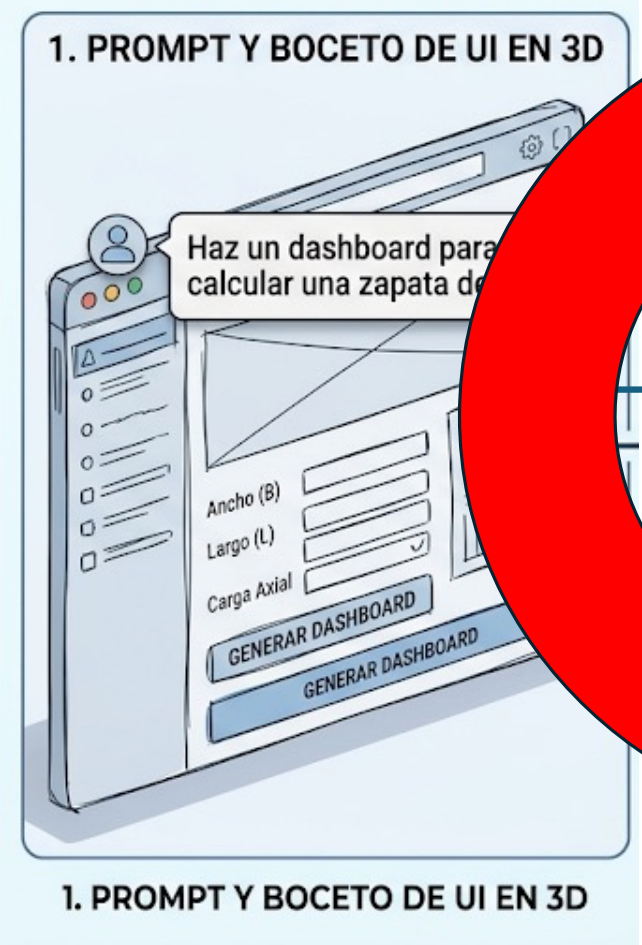
Nivel 3:
Proyectos inter-asignaturas

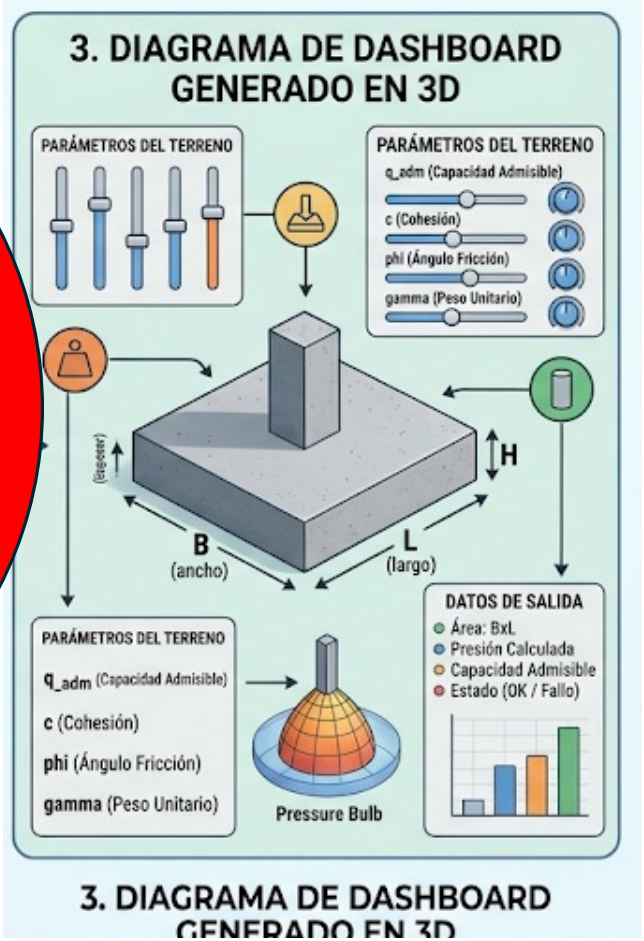


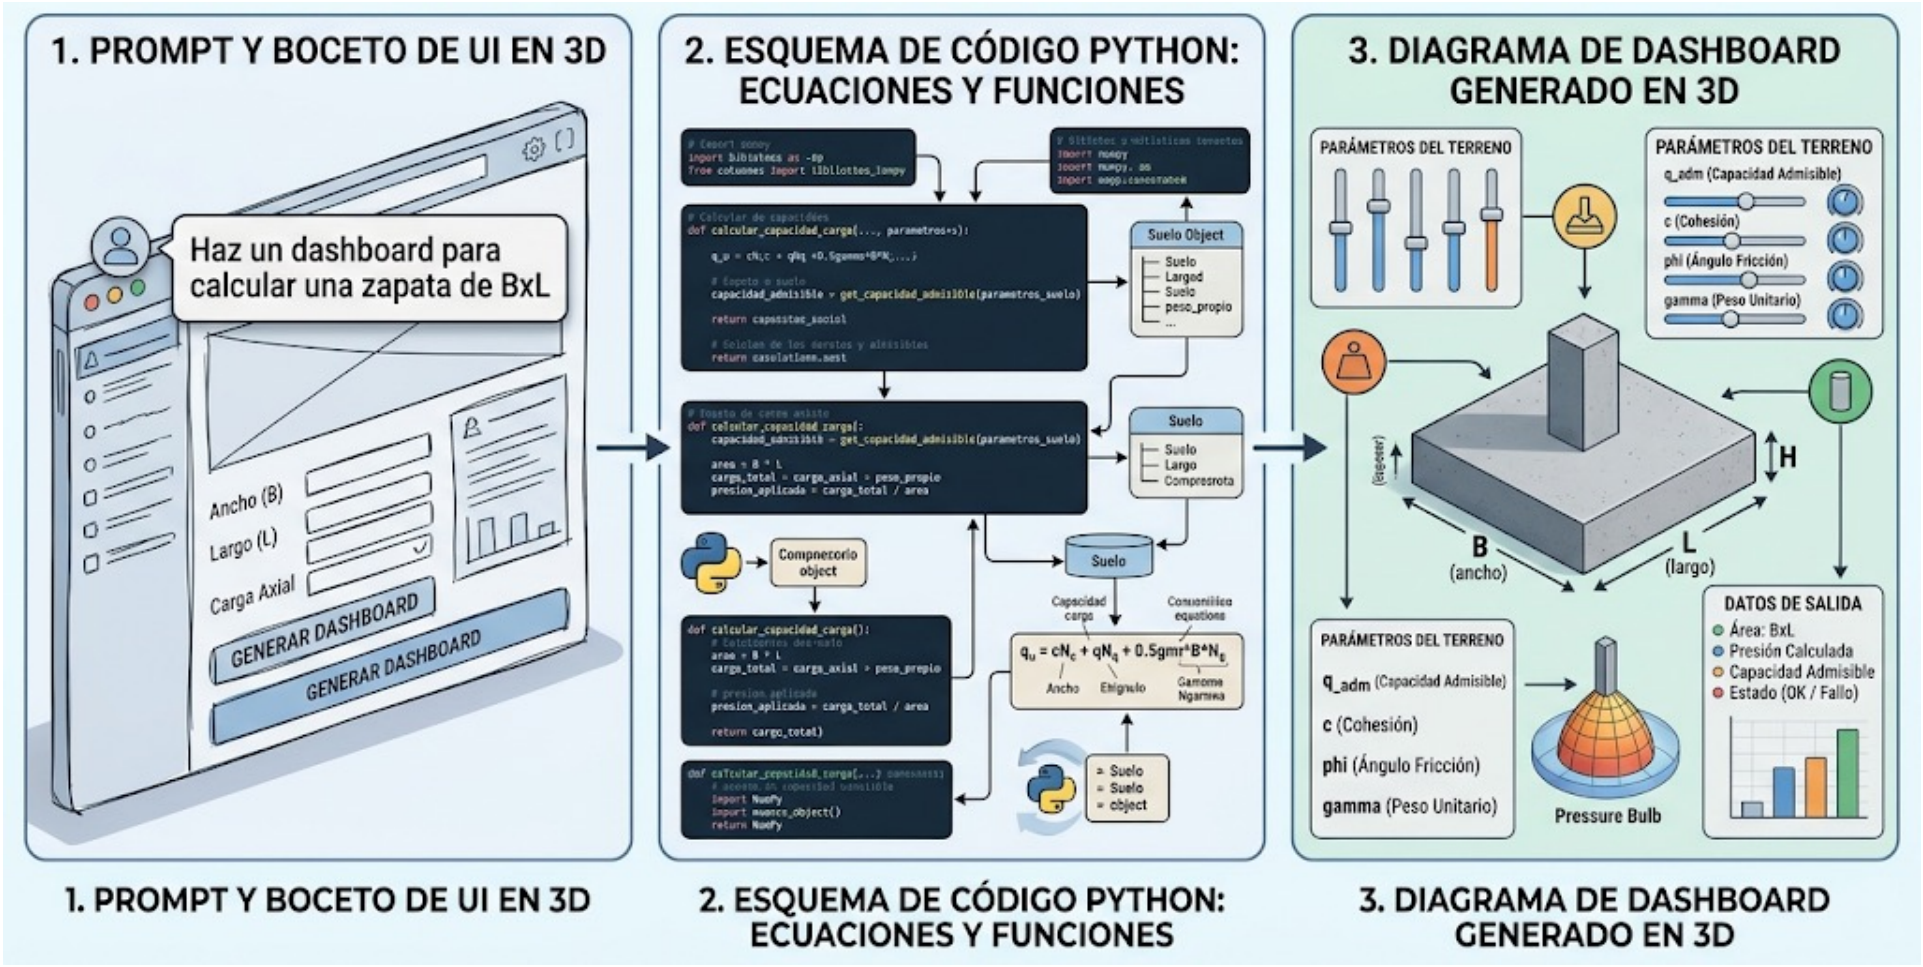


Gemini

Haz un dashboard para calcular la carga que soporta una zapata de dimensiones BxL

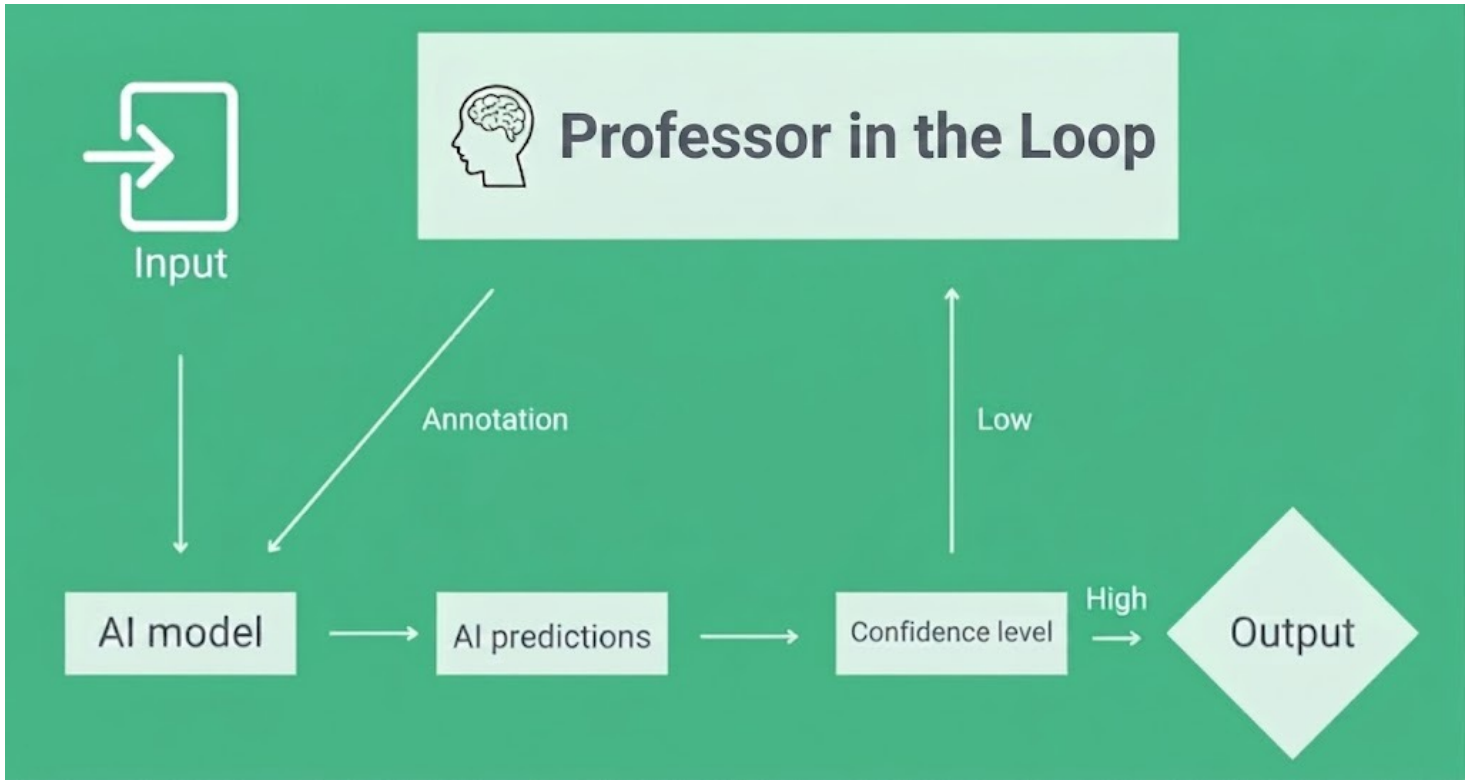






VERIFICACIÓN Y CORRECCIÓN

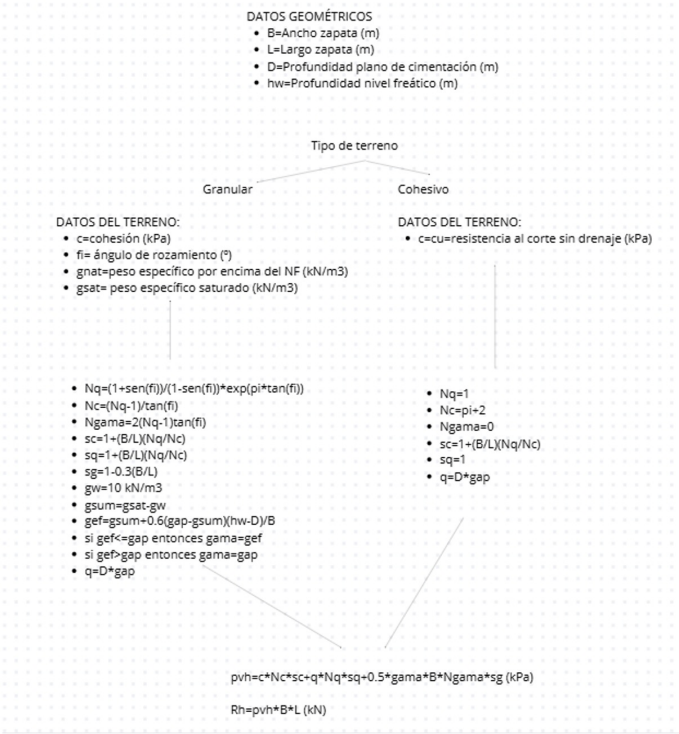
Verificación/Corrección



ORGANIGRAMA CÁLCULO RESISTENCIA AL HUNDIMIENTO DE UNA CIMENTACIÓN SUPERFICIAL

Notas:

- Sólo carga vertical
- Para factores de profundidad igual a la unidad
- Nivel freático por debajo del plano de cimentación



Gemini

Con base en el organigrama del notebook, haz un dashboard de jupyter notebook que distinga entre (a) terreno granular, y (b) terreno cohesivo. Que tenga claramente apartados para definir los parametros del tipo de terreno. Y que tenga ecualizadores de el ancho de la zapata, largo de la zapata, profundidad plano de la cimentacion, profundidad de nivel freativo, El dashboard tiene que representar el valor de la presion pvh y de la resistencia Rh. El dashboard tiene que visualizar en 3D los datos geometricos de entrada: B, L, D y hw

Verificación

Código para el Jupyter Notebook

Copia y pega el siguiente código en una celda de tu Jupyter Notebook y ejecútala. Asegúrate de tener instaladas las librerías `numpy`, `matplotlib` e `ipywidgets`.

Python

```
import numpy as np
import matplotlib.pyplot as plt
from mpl_toolkits.mplot3d.art3d import Poly3DCollection
import ipywidgets as widgets
from IPython.display import display, clear_output
import math

def calcular_capacidad(tipo_terreno, gamma, phi, c, B, L, D, hw):
    # Factores de capacidad de carga
    if tipo_terreno == 'Granular':
        phi_rad = math.radians(phi)
        Nq = math.exp(math.pi * math.tan(phi_rad)) * (math.tan(math.radians(45) + ph
        Ng = 2 * (Nq + 1) * math.tan(phi_rad)
        Nc = 0 # No se usa en suelo puramente granular

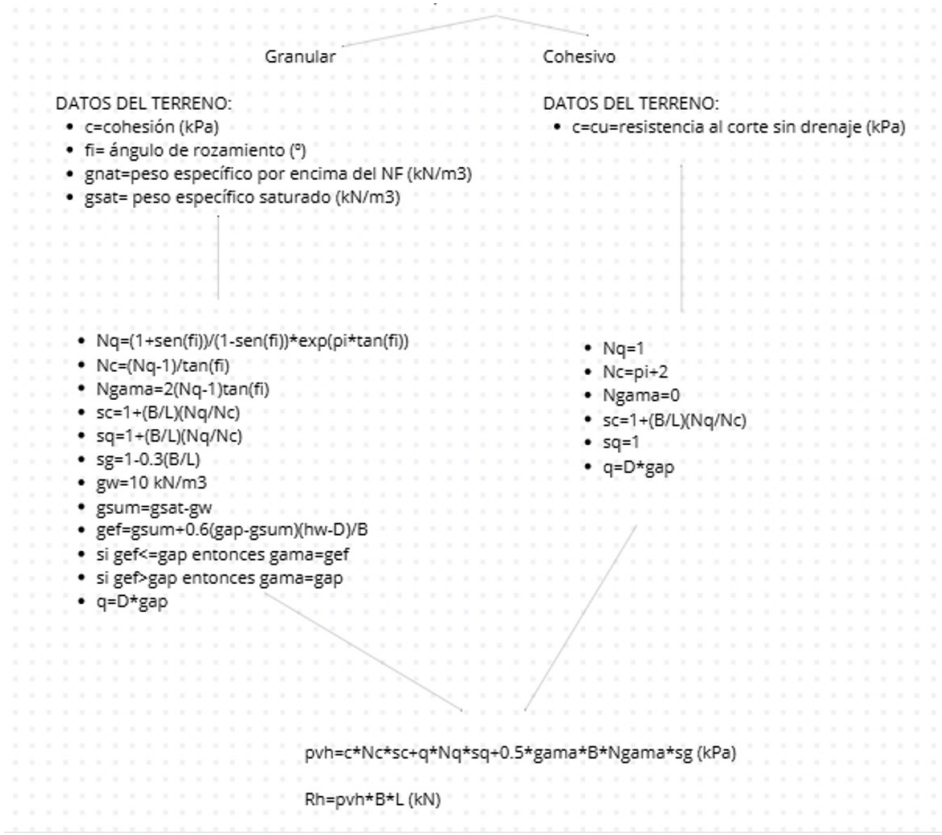
        # Factores de forma
        sq = 1 + (B/L) * math.sin(phi_rad)
        sg = 1 - 0.3 * (B/L)

        # Cálculo de p_vh
        pvh = (gamma * D * Nq * sq) + (0.5 * gamma * B * Ng * sg)

    else: # Terreno Cohesivo (Condición sin drenaje phi=0)
        Nq = 1.0
        Nc = 5.14
```

Ask Gemini Pro

Gemini is AI and can make mistakes, including about people. Your privacy & Gemini



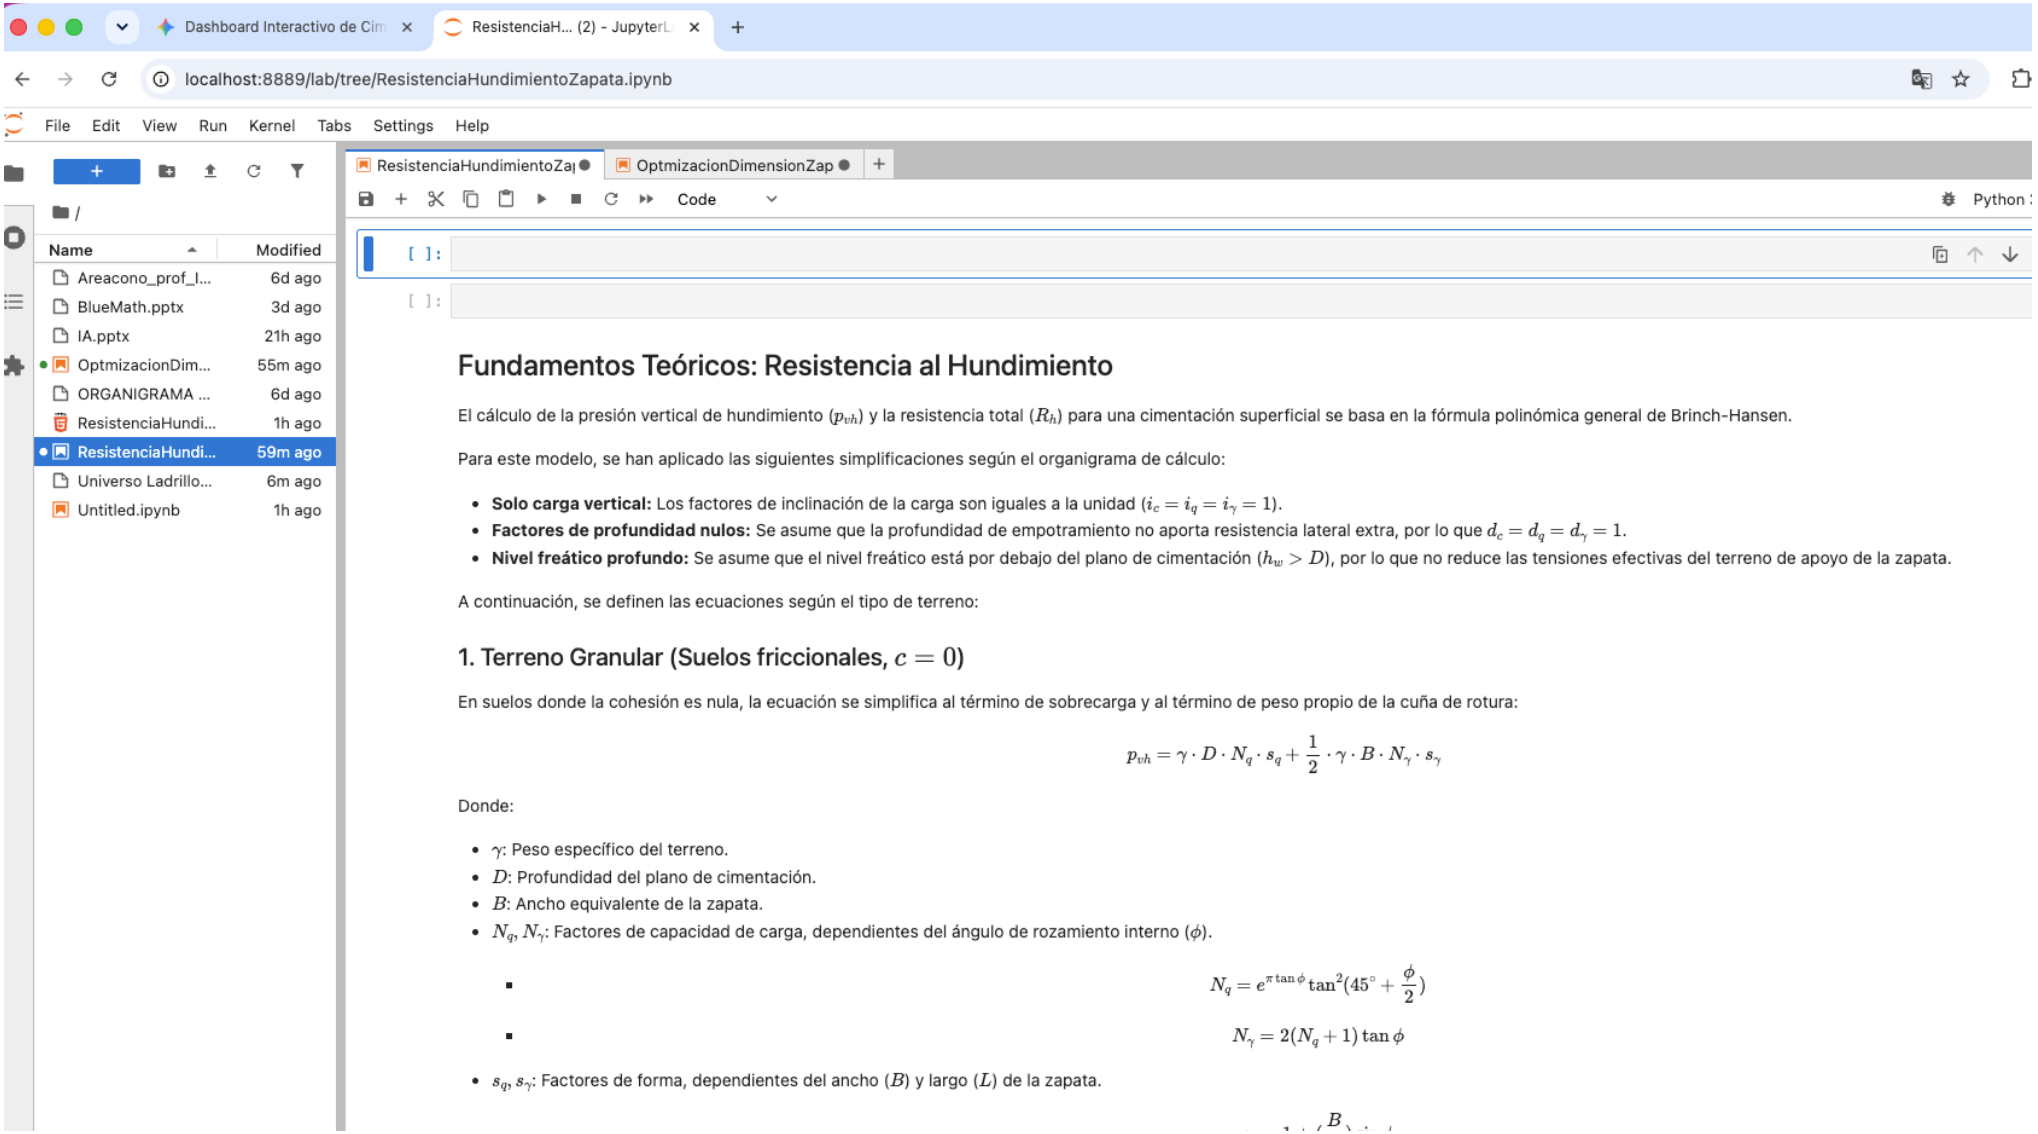

```python
import math

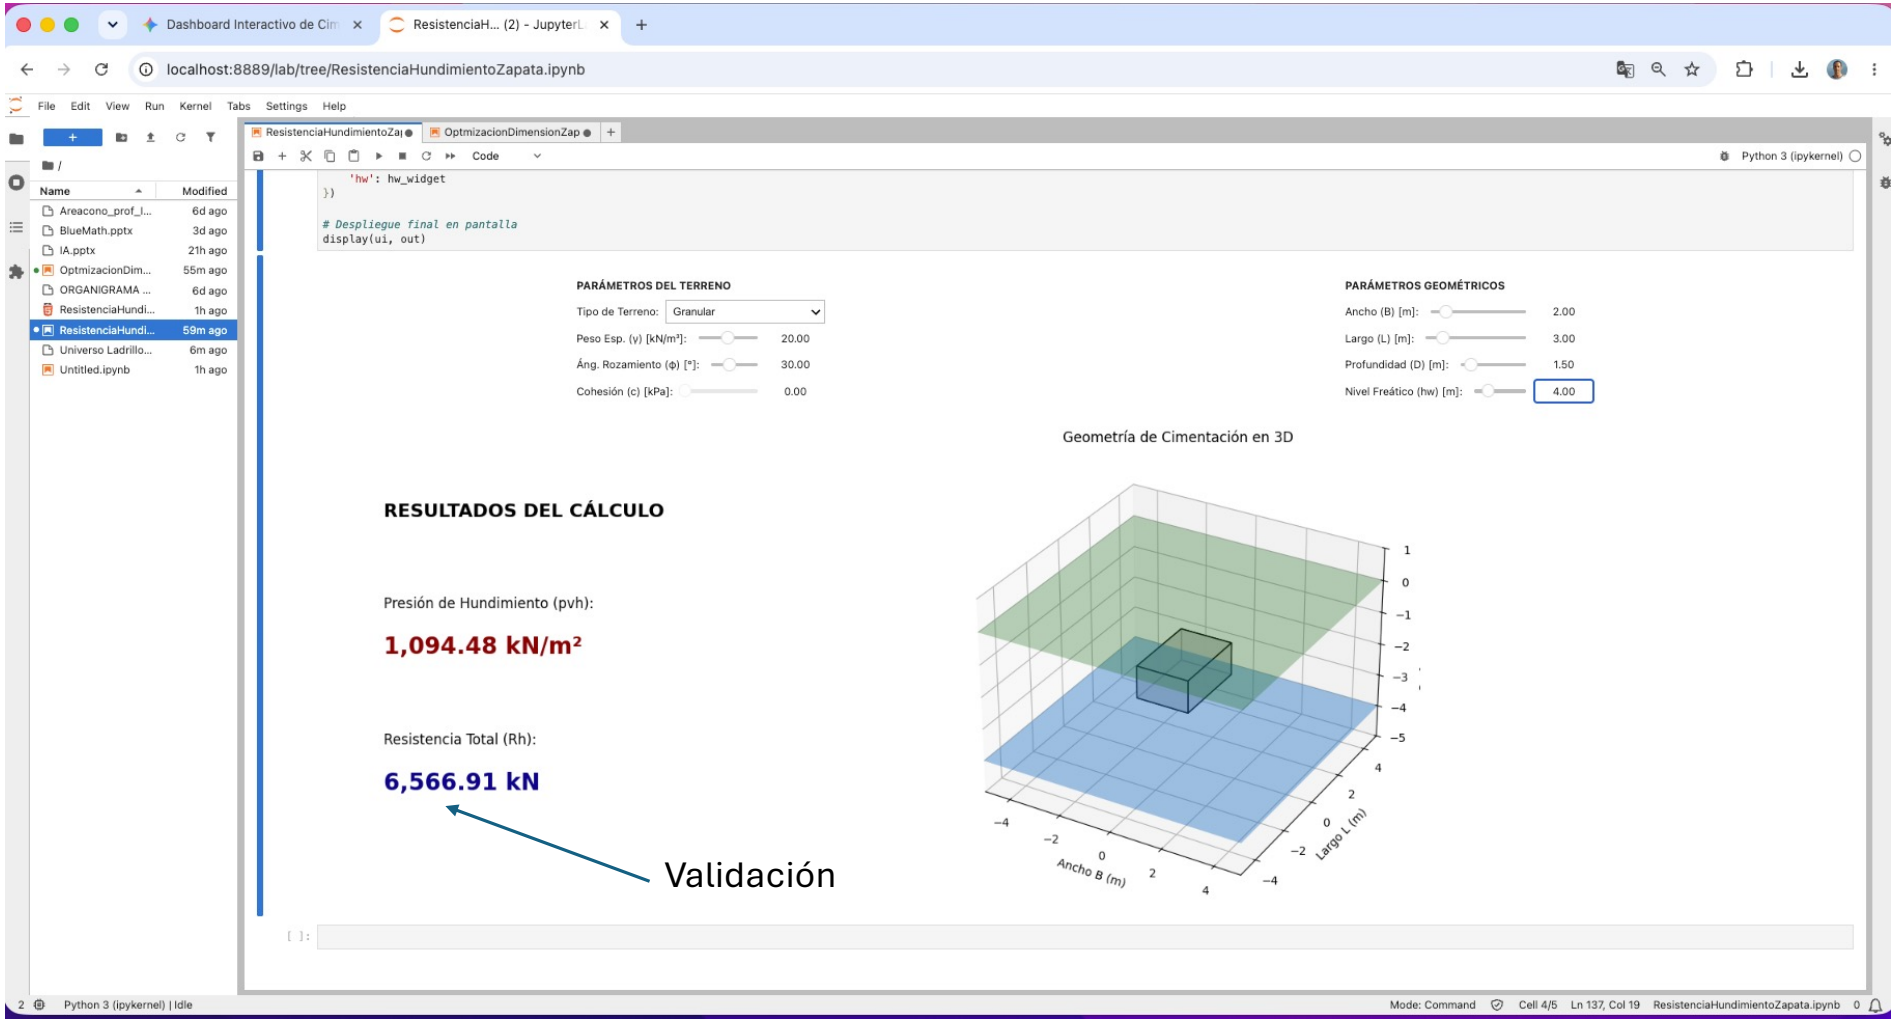
def calcular_capacidad(tipo_terreno, gamma, phi, c, B, L, D, hw):
    # Factores de capacidad de carga
    if tipo_terreno == 'Granular':
        phi_rad = math.radians(phi)
        Nq = math.exp(math.pi * math.tan(phi_rad)) * (math.tan(math.radians(45) + ph
        Ng = 2 * (Nq + 1) * math.tan(phi_rad)
        Nc = 0 # No se usa en suelo puramente granular

        # Factores de forma
        sq = 1 + (B/L) * math.sin(phi_rad)
        sg = 1 - 0.3 * (B/L)

        # Cálculo de p_vh
        pvh = (gamma * D * Nq * sq) + (0.5 * gamma * B * Ng * sg)

    else: # Terreno Cohesivo (Condición sin drenaje phi=0)
        Nq = 1.0
        Nc = 5.14
```

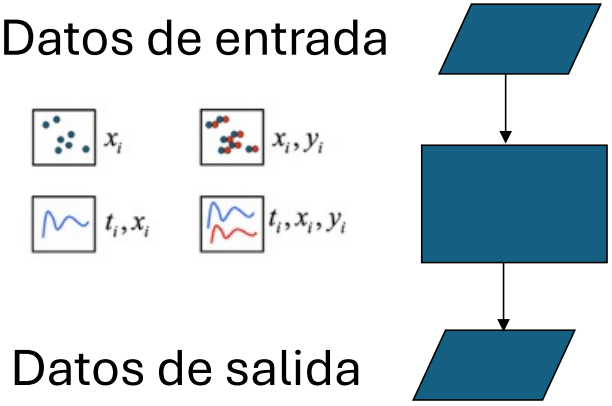

Dashboard Interactivo de Cim
ResistenciaH... (2) - JupyterL
localhost:8889/lab/tree/ResistenciaHundimientoZapata.ipynb
File Edit View Run Kernel Tabs Settings Help
ResistenciaHundimientoZa
OptmizacionDimensionZap
Code
Python
/
Name
Modified
Areacono_prof_I... 6d ago
BlueMath.pptx 3d ago
IA.pptx 21h ago
OptmizacionDim... 55m ago
ORGANIGRAMA ... 6d ago
ResistenciaHundi... 1h ago
ResistenciaHundi... 59m ago
Universo Ladrillo... 6m ago
Untitled.ipynb 1h ago
[ ]:
[ ]:
Fundamentos Teóricos: Resistencia al Hundimiento
El cálculo de la presión vertical de hundimiento (p_{vh}) y la resistencia total (R_h) para una cimentación superficial se basa en la fórmula polinómica general de Brinch-Hansen.
Para este modelo, se han aplicado las siguientes simplificaciones según el organigrama de cálculo:
Solo carga vertical: Los factores de inclinación de la carga son iguales a la unidad ($i_c = i_q = i_\gamma = 1$).
Factores de profundidad nulos: Se asume que la profundidad de empotramiento no aporta resistencia lateral extra, por lo que $d_c = d_q = d_\gamma = 1$.
Nivel freático profundo: Se asume que el nivel freático está por debajo del plano de cimentación ($h_w > D$), por lo que no reduce las tensiones efectivas del terreno de apoyo de la zapata.
A continuación, se definen las ecuaciones según el tipo de terreno:
1. Terreno Granular (Suelos friccionales, $c = 0$)
En suelos donde la cohesión es nula, la ecuación se simplifica al término de sobrecarga y al término de peso propio de la cuña de rotura:
$$p_{vh} = \gamma \cdot D \cdot N_q \cdot s_q + \frac{1}{2} \cdot \gamma \cdot B \cdot N_\gamma \cdot s_\gamma$$
Donde:
γ: Peso específico del terreno.
D: Profundidad del plano de cimentación.
B: Ancho equivalente de la zapata.
N_q, N_γ: Factores de capacidad de carga, dependientes del ángulo de rozamiento interno (ϕ).
$N_q = e^{\pi \tan \phi} \tan^2(45^\circ + \frac{\phi}{2})$
$N_\gamma = 2(N_q + 1) \tan \phi$
s_q, s_γ: Factores de forma, dependientes del ancho (B) y largo (L) de la zapata.


Dashboard Interactivo de Cim
ResistenciaH... (2) - JupyterL
localhost:8889/lab/tree/ResistenciaHundimientoZapata.ipynb
File Edit View Run Kernel Tabs Settings Help
ResistenciaHundimientoZap
OptmizacionDimensionZap
Code
Python 3 (ipykernel)
'hw': hw_widget
})
Despliegue final en pantalla
display(ui, out)
Name
Modified
Areacono_prof_l... 6d ago
BlueMath.pptx 3d ago
IA.pptx 21h ago
OptmizacionDim... 55m ago
ORGANIGRAMA ... 6d ago
ResistenciaHundi... 1h ago
ResistenciaHundi... 59m ago
Universo Ladrillo... 6m ago
Untitled.ipynb 1h ago
PARÁMETROS DEL TERRENO
Tipo de Terreno: Granular
Peso Esp. (γ) [kN/m³]: 20.00
Áng. Rozamiento (ϕ) [°]: 30.00
Cohesión (c) [kPa]: 0.00
PARÁMETROS GEOMÉTRICOS
Ancho (B) [m]: 2.00
Largo (L) [m]: 3.00
Profundidad (D) [m]: 1.50
Nivel Freático (hw) [m]: 4.00
Geometría de Cimentación en 3D
RESULTADOS DEL CÁLCULO
Presión de Hundimiento (pvh):
1,094.48 kN/m²
Resistencia Total (Rh):
6,566.91 kN
Validación
Ancho B (m)
Largo L (m)
[ ]:
Python 3 (ipykernel) | Idle
Mode: Command
Cell 4/5
Ln 137, Col 19
ResistenciaHundimientoZapata.ipynb

Tipos de Bloques



Datos de entrada



Datos de salida

- Operación matemática = función, Integral,…
- Descargar Datos
- Leer ficheros / Transformar Ficheros
- Automatizar procesos en el PC (como bash)
- Superficie de interpolación
- Ecuación Diferencial
- Optimización
- Modelo de regresión
- Técnica de Aprendizaje Automático
- Red Neuronal
- Modelo Numérico
- Pregunta específica a un Manual/Norma de Diseño
- …

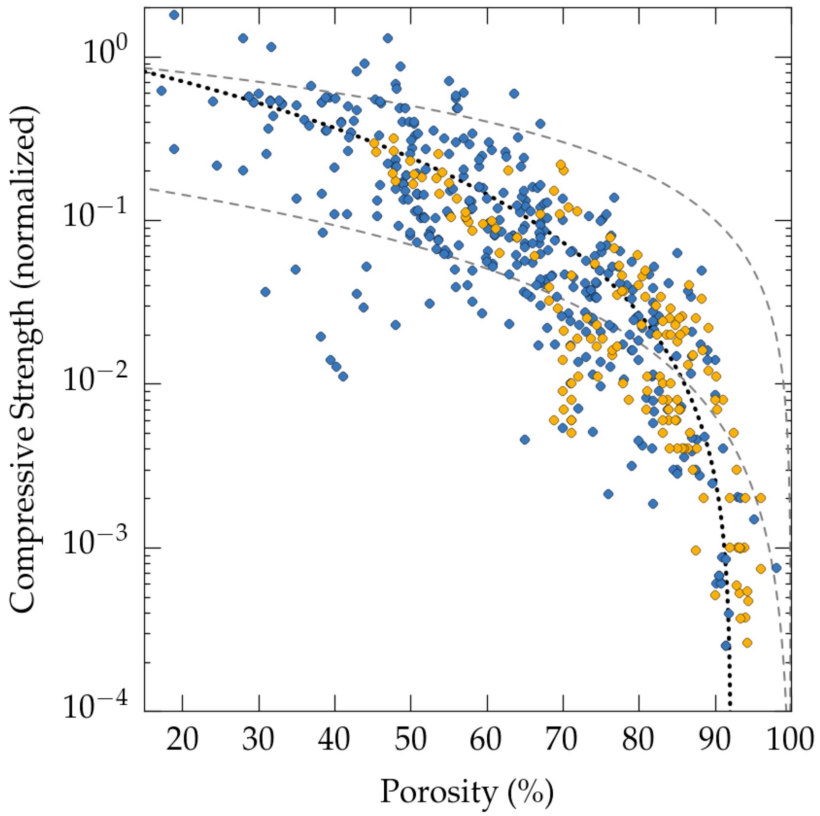
jupyter A meta-analysis of the mechanical properties of ice-templated cer… Last Checkpoint: 12/17/2018 (unsaved changes) Logout

File Edit View Insert Cell Kernel Widgets Help Not Trusted Python 3

Run Markdown

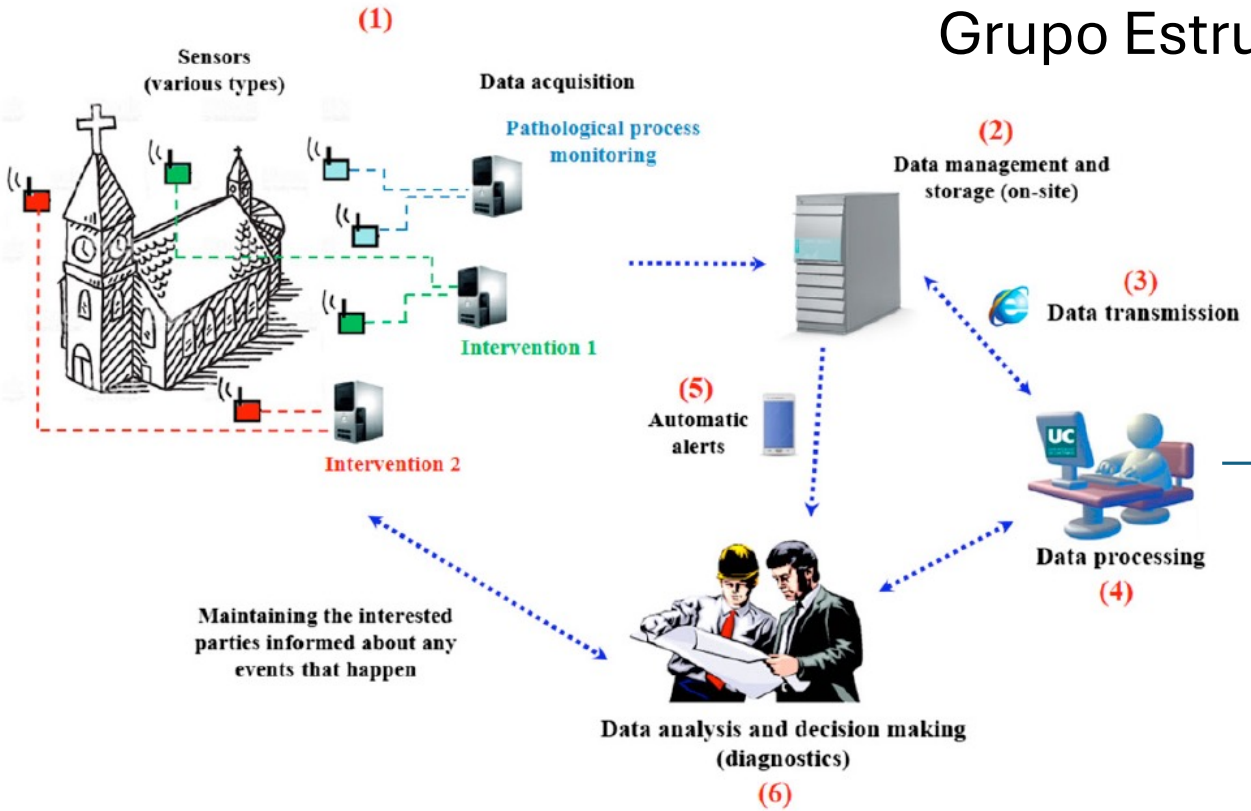
```
ymax = 2
plt.ylim(ymin, ymax)
plt.xlim(xmin, xmax)

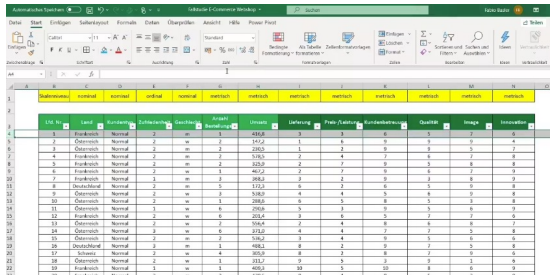
plt.tight_layout()
fig.savefig('../figures/figure6.png')
```



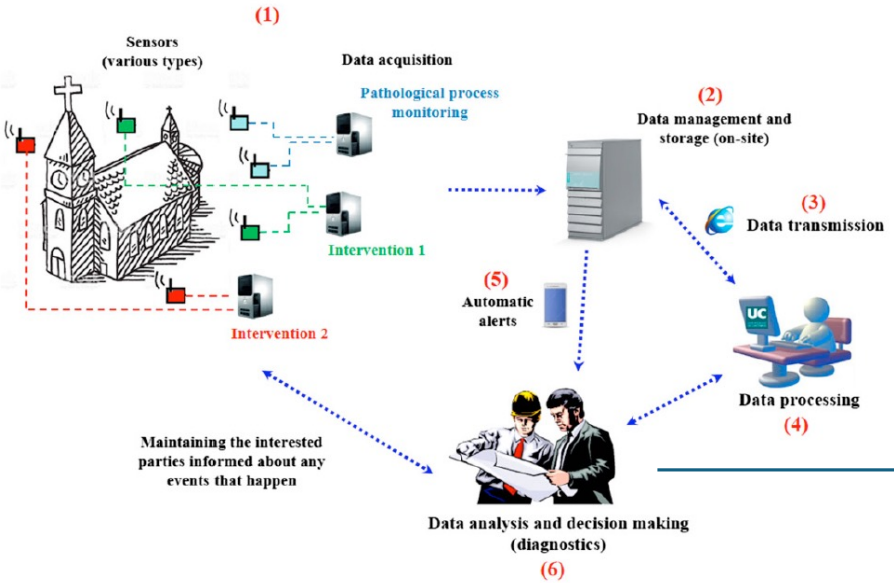
In [154]:
```
# parameters of the fit
print 'Exponent of the power law: '+str(fitParamsIT[1])
```

Grupo Estructuras (Nacho Lombillo)





Problema: Auscultación Iglesia Seminario Comillas
Data: 25 Sensores desplazamiento e inclinación, viento, temperatura, series de 5 años
Patrones de desplazamiento en función de Temperatura y Viento




```
: # scatterplot every variable vs. every variable (using matplotlib.gridspec)

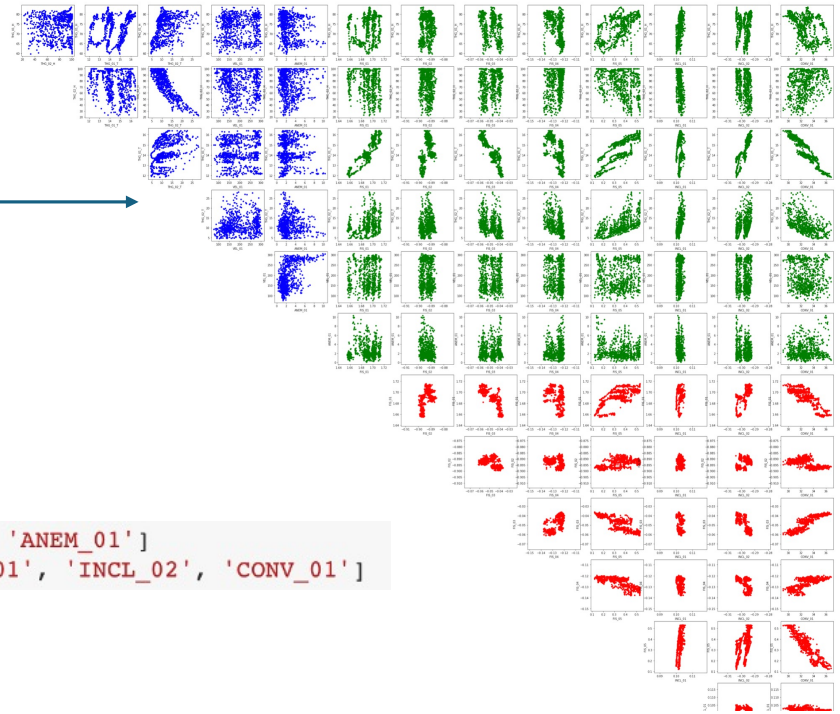
  # def aux. function
  def GetScatterColor(v1, v2, set_1, set_2):
      'returns custom colors for v1,v2 pairs depending on sets'

      if v1 in set_1 and v2 in set_1: return 'b'
      elif v1 in set_2 and v2 in set_2: return 'r'
      else: return 'g'


  # separate variables in input - output
  l_input = ['THG_01_H', 'THG_02_H', 'THG_01_T', 'THG_02_T', 'VEL_01', 'ANEM_01']
  l_output = ['FIS_01', 'FIS_02', 'FIS_03', 'FIS_04', 'FIS_05', 'INCL_01', 'INCL_02', 'CONV_01']
  vars_plot = l_input + l_output
  vars_num = len(vars_plot)

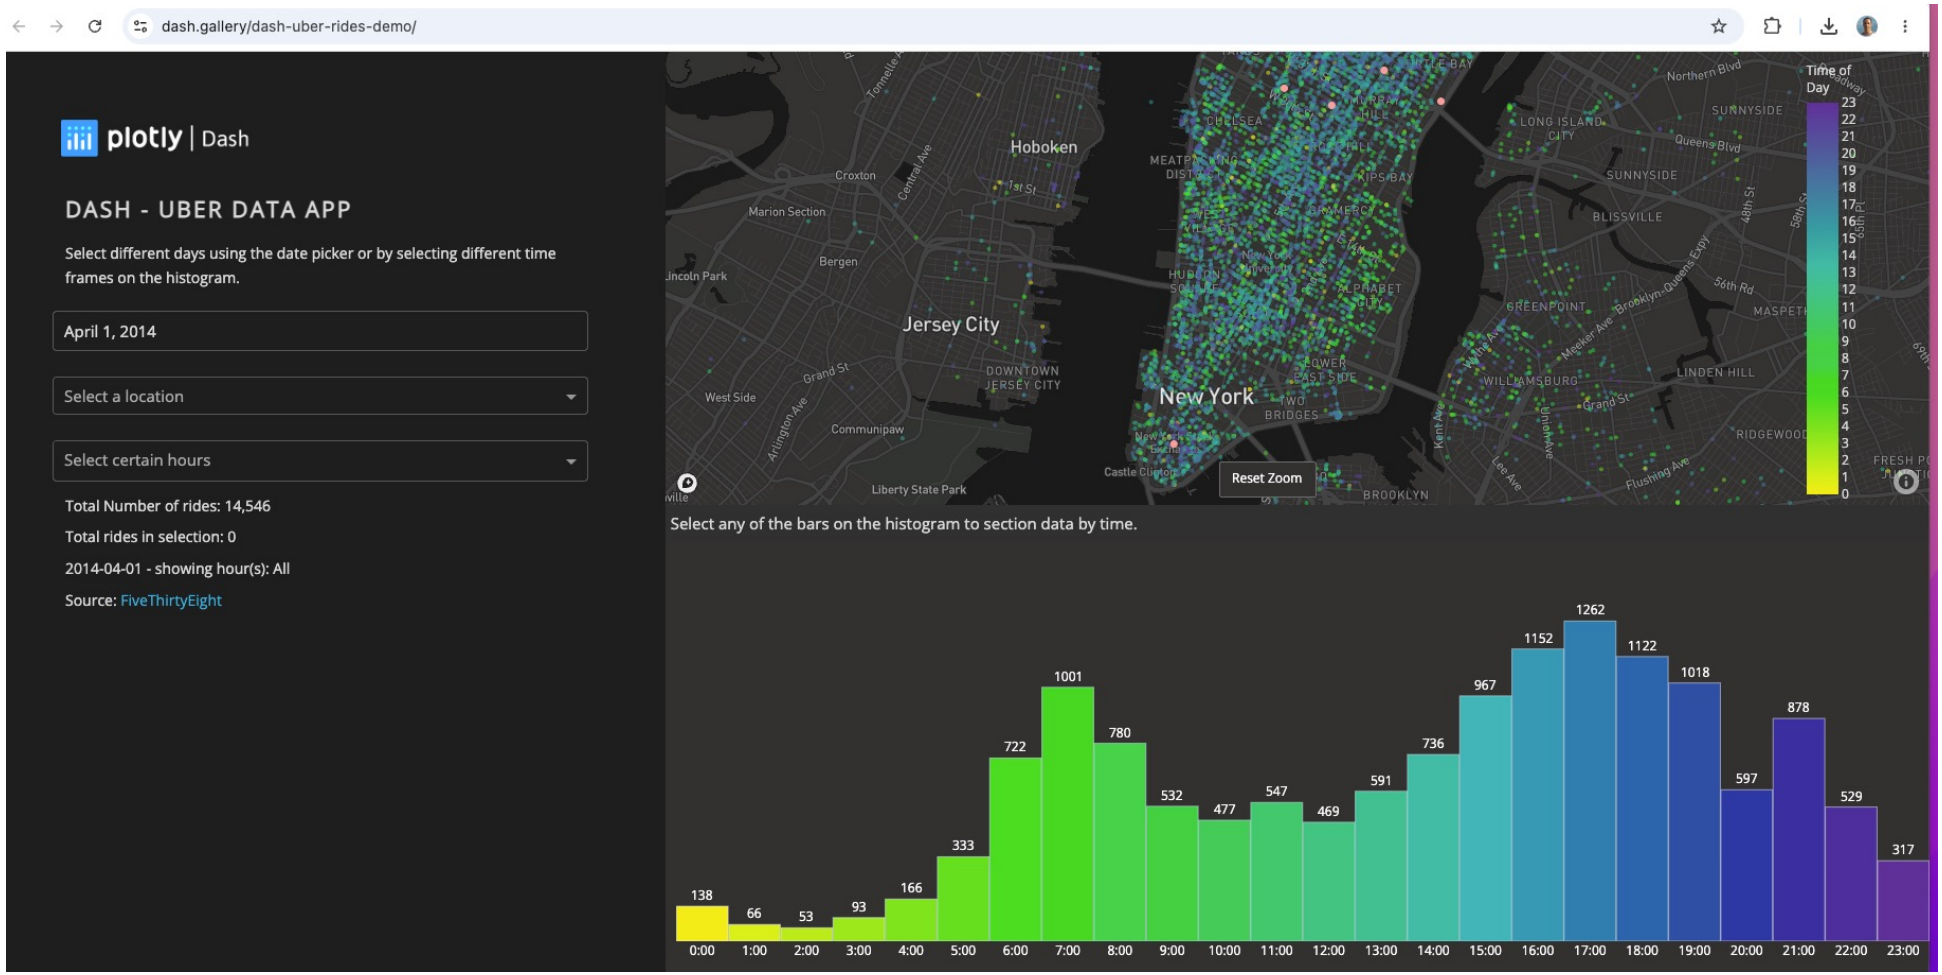
  # plot  figure
  fig = plt.figure(figsize=(56,56))
  gs = gridspec.GridSpec(vars_num, vars_num, figure=fig)

  for c1, v1 in enumerate(vars_plot):
      for c2, v2 in enumerate(vars_plot):
          if c1 > c2:
              ax = plt.subplot(gs[c2, c1])
              data_res.plot.scatter(
                  x=v1, y=v2, ax=ax, c=GetScatterColor(v1,v2, l_input, l_output)
              )
  plt.show()
```

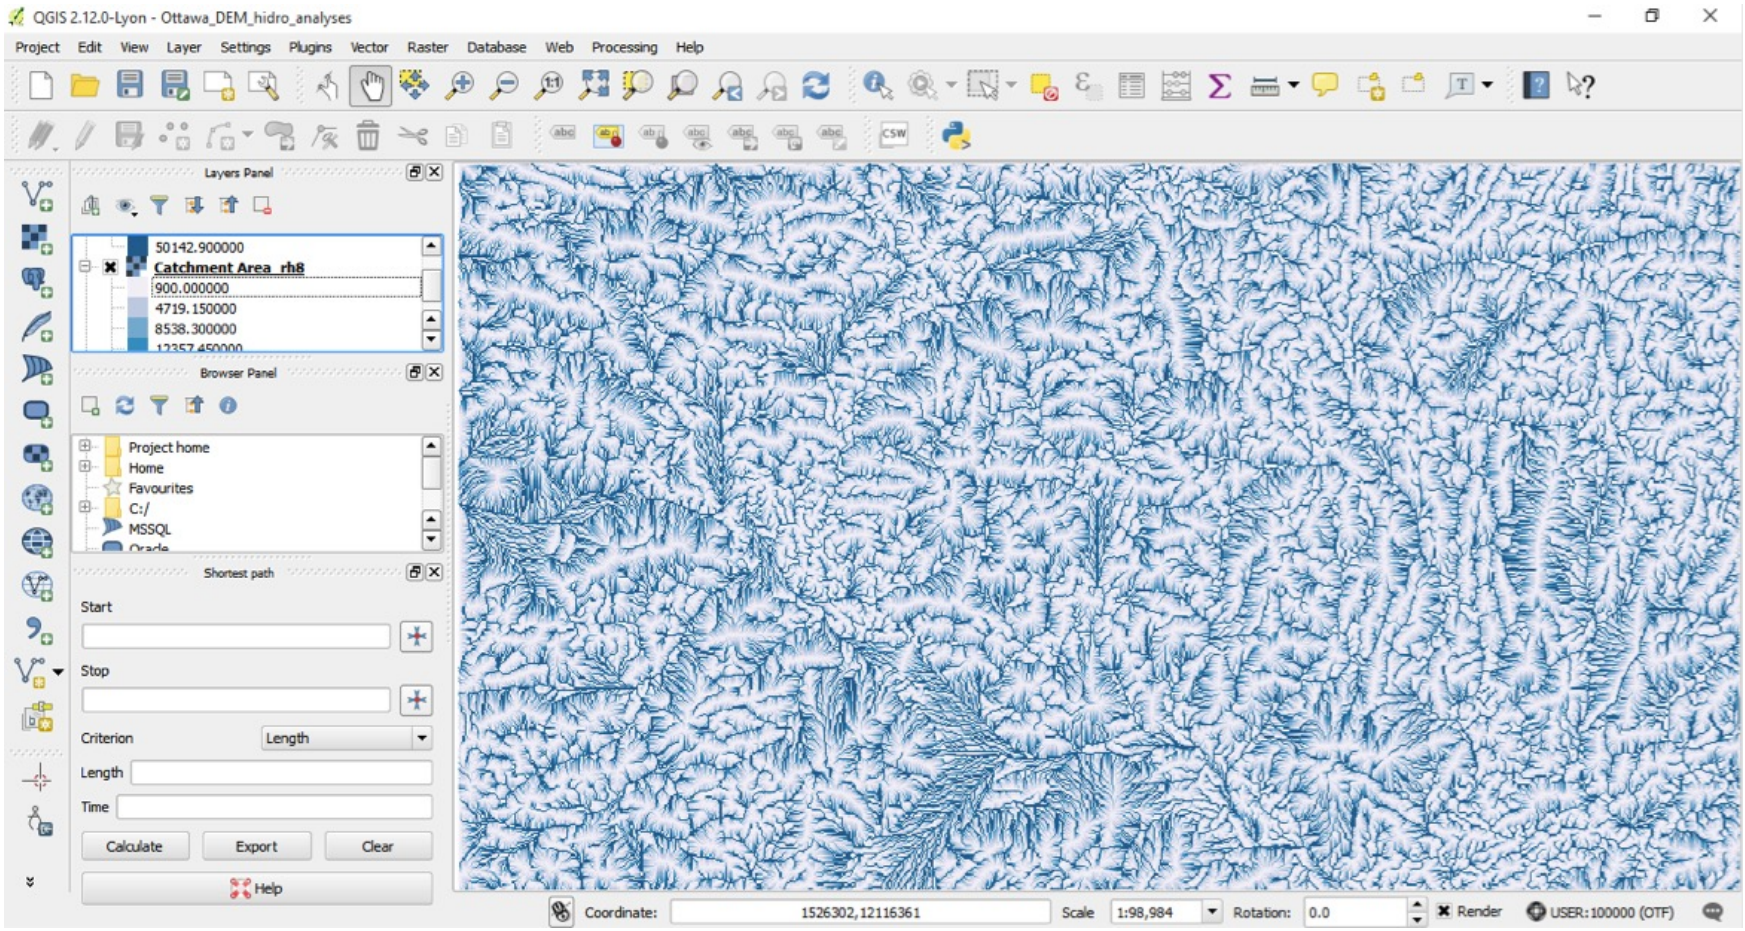


```
l_input = ['THG_01_H', 'THG_02_H', 'THG_01_T', 'THG_02_T', 'VEL_01', 'ANEM_01']
l_output = ['FIS_01', 'FIS_02', 'FIS_03', 'FIS_04', 'FIS_05', 'INCL_01', 'INCL_02', 'CONV_01']
```

Datos Discretos GIS + EDA



Ejemplo en QGIS: MDT -> Algoritmo -> Red de Rios



hydra-web.yellowwave-5aaa93b0.spaincentral.azurecontainerapps.io/jupyter/lab/workspaces/auto-W/tree/919ee7a2971842f3b8f4977c38676e88/notebooks/pilot_cases/los_corrales_buelna/03_extreme_val...

Relaunch to upd

File Edit View Run Kernel Tabs Settings Help

/ pilot_cases / los_corrales_buelna /

Name	Modified
01_data_acquisit...	18s ago
02_spatial_inter...	18s ago
03_extreme_valu...	18s ago
04_design_stor...	18s ago
05_continuous_s...	17s ago
06_hybrid_event...	17s ago
07_hec_ras_hydr...	17s ago
07_hec_ras_hydr...	17s ago
08_hybrid_retur...	16s ago

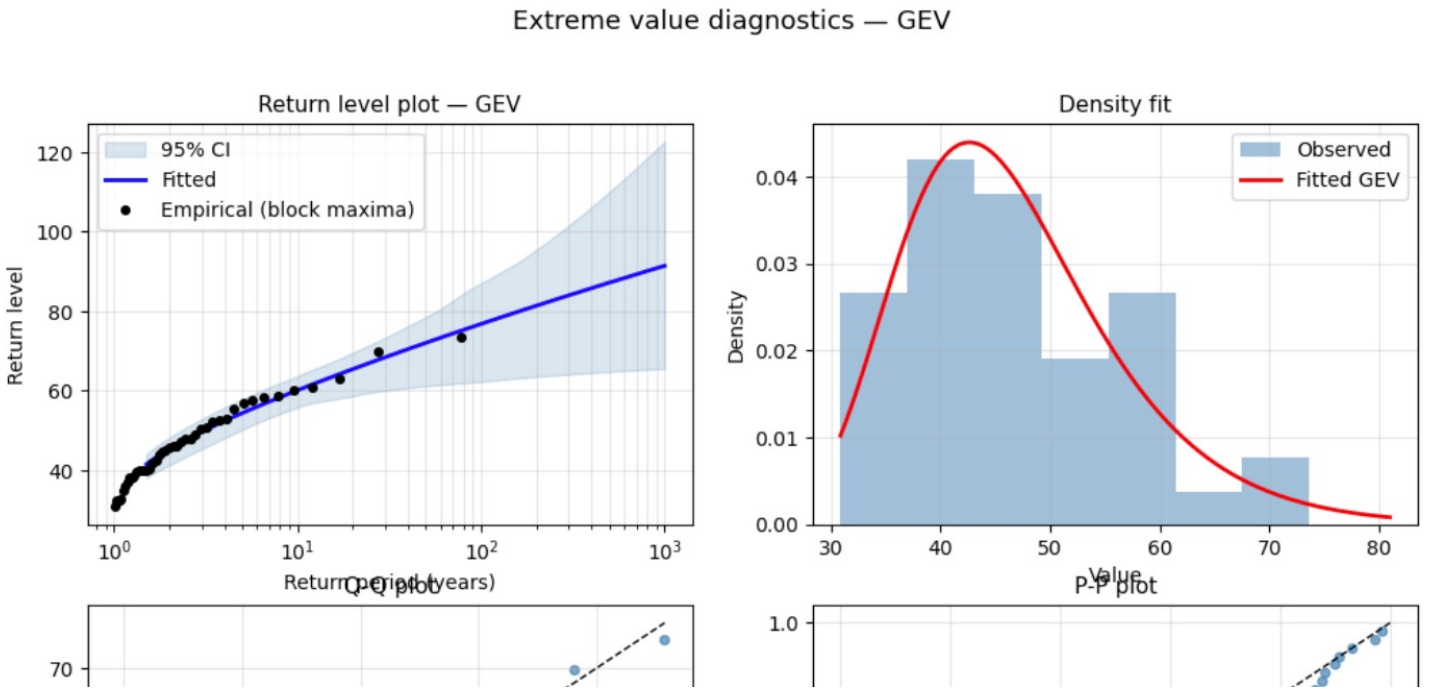
03_extreme_value_analysis

Markdown

Python 3 (ipykernel)

[4]:

```
# Visual diagnostic
fig = plot_diagnostic(annual_max.values, params_gev, dist='gev')
plt.savefig(PROC_DIR / 'gev_diagnostic.png', dpi=150)
plt.show()
```



{ClimateServices}

TC Coastal Inundation System {book}

Search this book...

TC Coastal Inundation System

SHYTCWAVES

SHyTCWaves validation

GREENSURGE

GreenSurge Validation

Astronomical Tide Validation

HISTORICAL TC

Historical TC : Evan (2012)

TC RE-FORECAST FLOODING

TC Inundation

Upolu

From Offshore to Coastline

From Offshore to Coastal Flooding

Coastal Flooding Impact

Savaii

Powered by Jupyter Book

Plot Hazard - SWATH

```
a_file = open(p_kepler_config_hazard, "rb")
config_hazard= json.load(a_file)

# Hazard - flooding depth
map_1 = KeplerGl(height=700, data={"Depth ": df_sim_84}, config=config_hazard, show_doc
```

```
map_1
```



Contents

Forecast Parameteres

Database

Reforecast

Flooding to raster

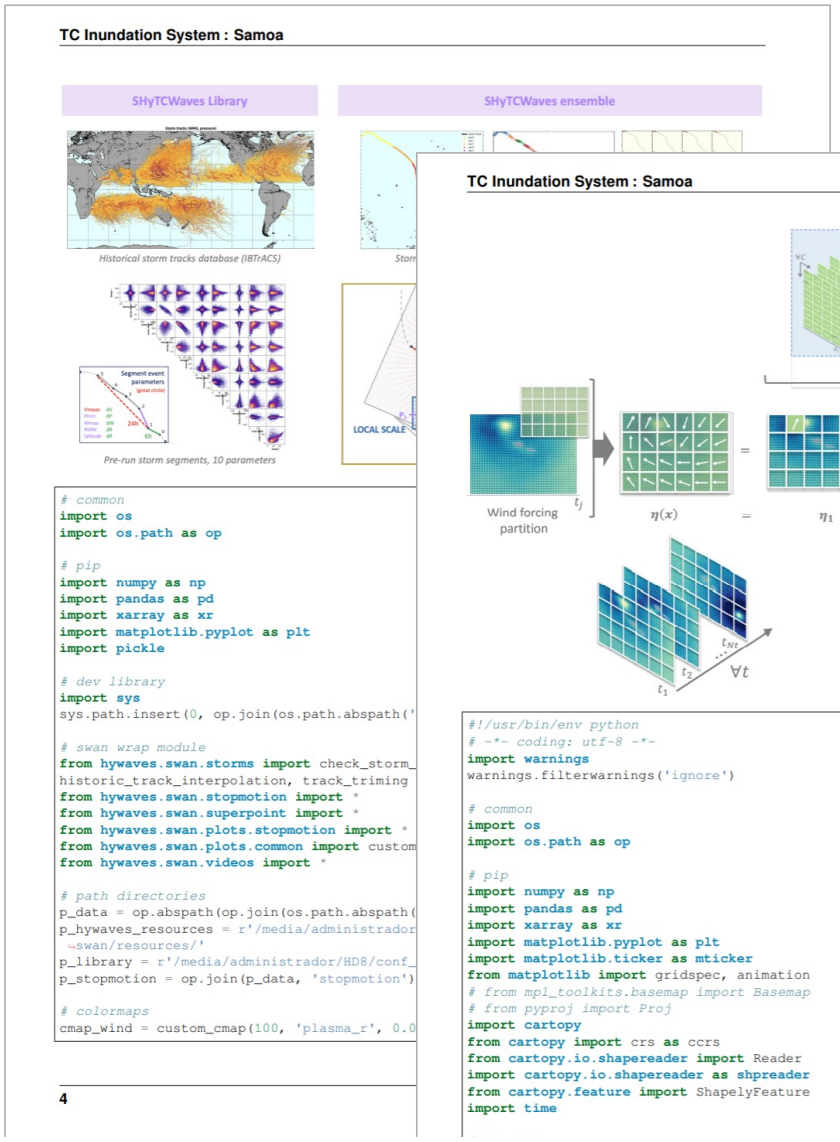
Plot Hazard - SWATH

RiskScape

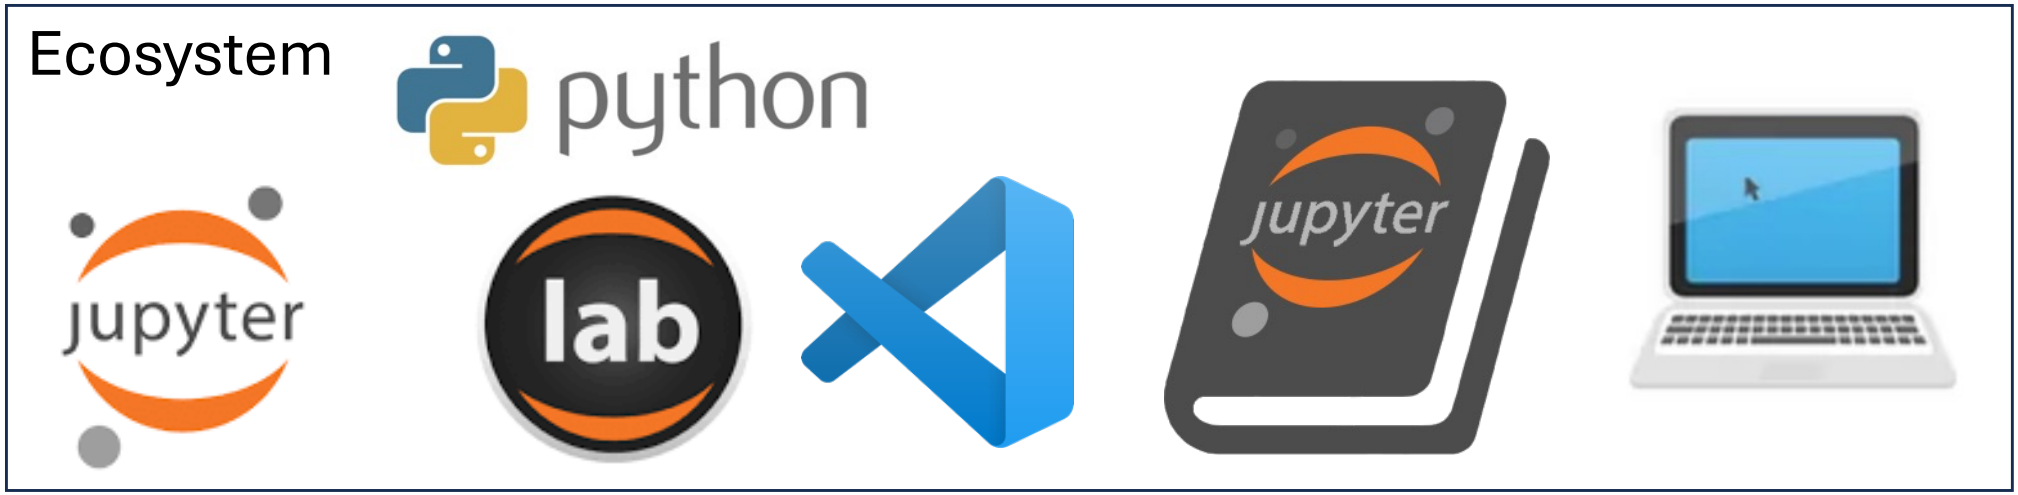


Jupyter Books

- HTML
- PDF







Instalación de VS Code + Python + GitHub


¿Qué es la IA?



Pioneros de la IA en Dartmouth. Source: Consejo Científico Internacional - International Science Council / La IA nació en un campamento de verano en Estados Unidos en 1956

A PROPOSAL FOR THE DARTMOUTH SUMMER RESEARCH PROJECT ON ARTIFICIAL INTELLIGENCE

J. McCarthy, Dartmouth College
M. L. Minsky, Harvard University
N. Rochester, I.B.M. Corporation
C.E. Shannon, Bell Telephone Laboratories

August 31, 1955

We propose that a 2 month, 10 man study of artificial intelligence be carried out during the summer of 1956 at Dartmouth College in Hanover, New Hampshire. The study is to proceed on the basis of the conjecture that every aspect of learning or any other feature of intelligence can in principle be so precisely described that a machine can be made to simulate it. An attempt will be made to find how to make machines use language, form abstractions and concepts, solve kinds of problems now reserved for humans, and improve themselves. We think that a significant advance can be made in one or more of these problems if a carefully selected group of scientists work on it together for a summer.

¿Que es la IA?

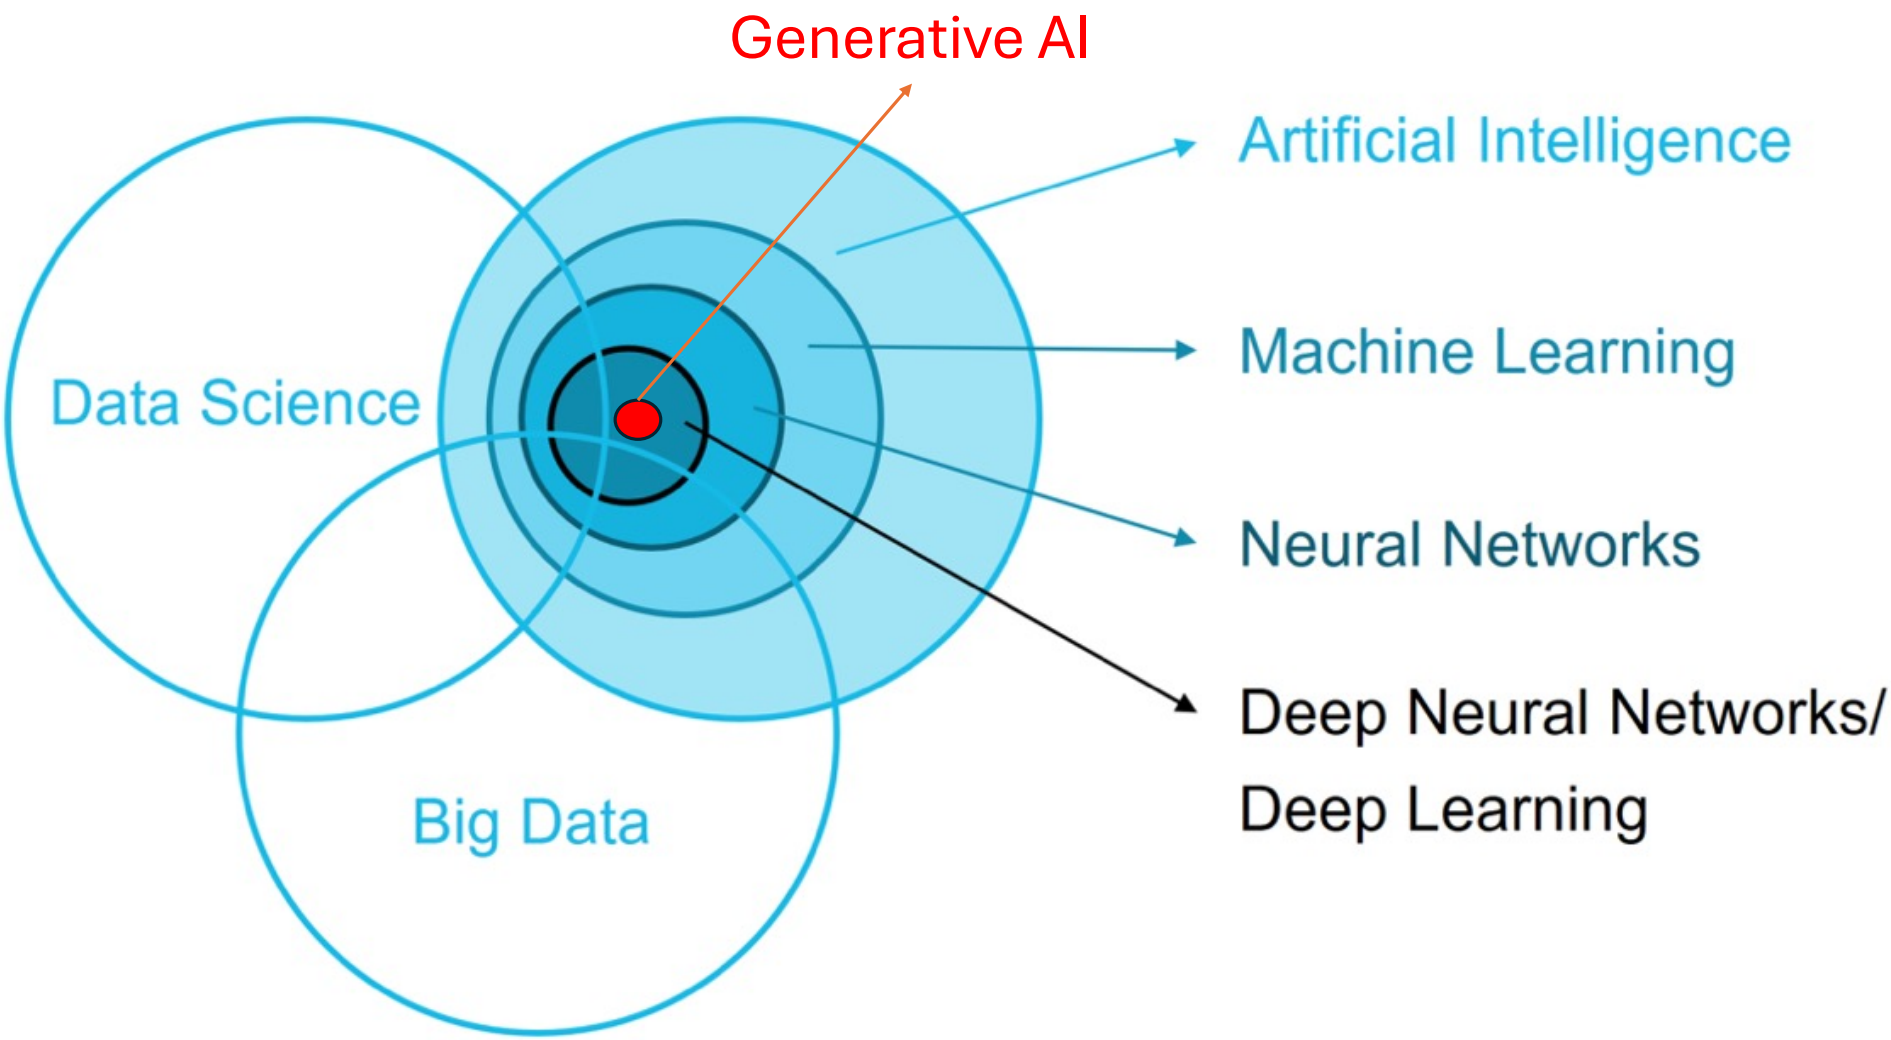
WikiPedia



La **inteligencia artificial**, abreviada como **IA** o **AI** (por su nombre en inglés: *artificial intelligence*), en el contexto de las ciencias de la computación, es una disciplina y un conjunto de capacidades cognoscitivas e intelectuales expresadas por sistemas informáticos o combinaciones de algoritmos cuyo propósito es la creación de máquinas que imiten la inteligencia humana.

Estas tecnologías permiten que las máquinas aprendan de la experiencia, se adapten a nuevas entradas y realicen tareas humanas como el reconocimiento de voz, la toma de decisiones, la traducción de idiomas o la visión por computadora




Generative AI
Artificial Intelligence
Machine Learning
Neural Networks
Deep Neural Networks/
Deep Learning
Data Science
Big Data

El Mapa de la Inteligencia Artificial: De los Algoritmos Clásicos a la Era Generativa

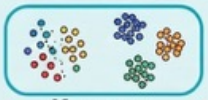
Paradigma Principal: Aprendizaje Clásico

APRENDIZAJE NO SUPERVISADO

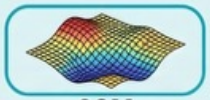
Explora Patrones Ocultos



PCA
Dimension Reduction



K-means
Clustering



SOM
Self-Organizing Maps

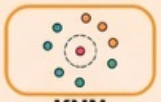
Buscan patrones ocultos sin etiquetas, simplifican dimensiones y agrupan datos.

APRENDIZAJE SUPERVISADO

Usa Datos Etiquetados



GLM
Modelos Lineales



KNN
Vecinos Cercanos



SVM
Máquinas de Soporte



Boost
Gradient Boosting

Aprenden de ejemplos con etiquetes para clasificar o predecir resultados.

Evolución a Redes Neuronales y Aprendizaje Profundo

ANN
Redes Neuronales Artificiales



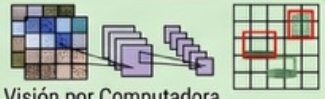


DNN
Redes Profundas

Evolución de redes simples a múltiples capas para procesar información compleja.

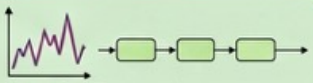
Arquitecturas Especializadas

CNN



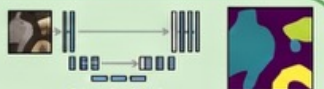
Visión por Computadora

LSTM



Secuencias Temporales

U-Net

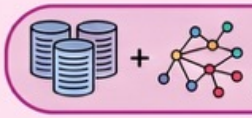


Segmentación de Imágenes

Arquitecturas diseñadas para tipos de datos especificos como imágenes y secuencias.

Revolución de los Transformers y IA Generativa

TRANSFORMERS



LLM
Modelos de Lenguaje Masivos



GPT
Generative Pre-trained Transformer



El procesamiento paralelo del Transformer impulsa modelos generativos capaces de crear contenido y comprender lenguaje a gran escala.

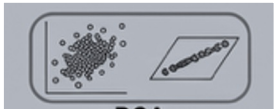
NotebookLM

El Mapa de la Inteligencia Artificial: De los Algoritmos Clásicos a la Era Generativa

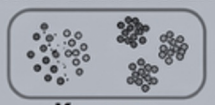
Paradigma Principal: Aprendizaje Clásico

APRENDIZAJE NO SUPERVISADO

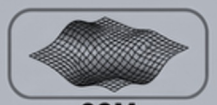
Explora Patrones Ocultos



PCA
Dimension Reduction



K-means
Clustering



SOM
Self-Organizing Maps

Buscan patrones ocultos sin etiquetas, simplifican dimensiones y agrupan datos.

APRENDIZAJE SUPERVISADO

Usa Datos Etiquetados



GLM
Modelos Lineales



KNN
Vecinos Cercanos



SVM
Máquinas de Soporte



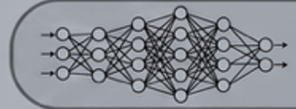
Boost
Gradient Boosting

Aprenden de ejemplos con etiquetes para clasificar o predecir resultados.

Evolución a Redes Neuronales y Aprendizaje Profundo

ANN
Redes Neuronales Artificiales





DNN
Redes Profundas

Evolución de redes simples a múltiples capas para procesar información compleja.

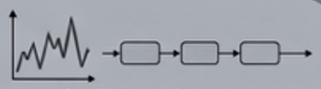
Arquitecturas Especializadas

CNN



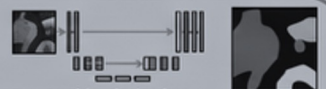
Visión por Computadora

LSTM



Secuencias Temporales

U-Net



Segmentación de Imágenes

Arquitecturas diseñadas para tipos de datos especificos como imágenes y secuencias.

Revolución de los Transformers y IA Generativa

TRANSFORMERS



LLM
Modelos de Lenguaje Masivos



GPT
Generative Pre-trained Transformer

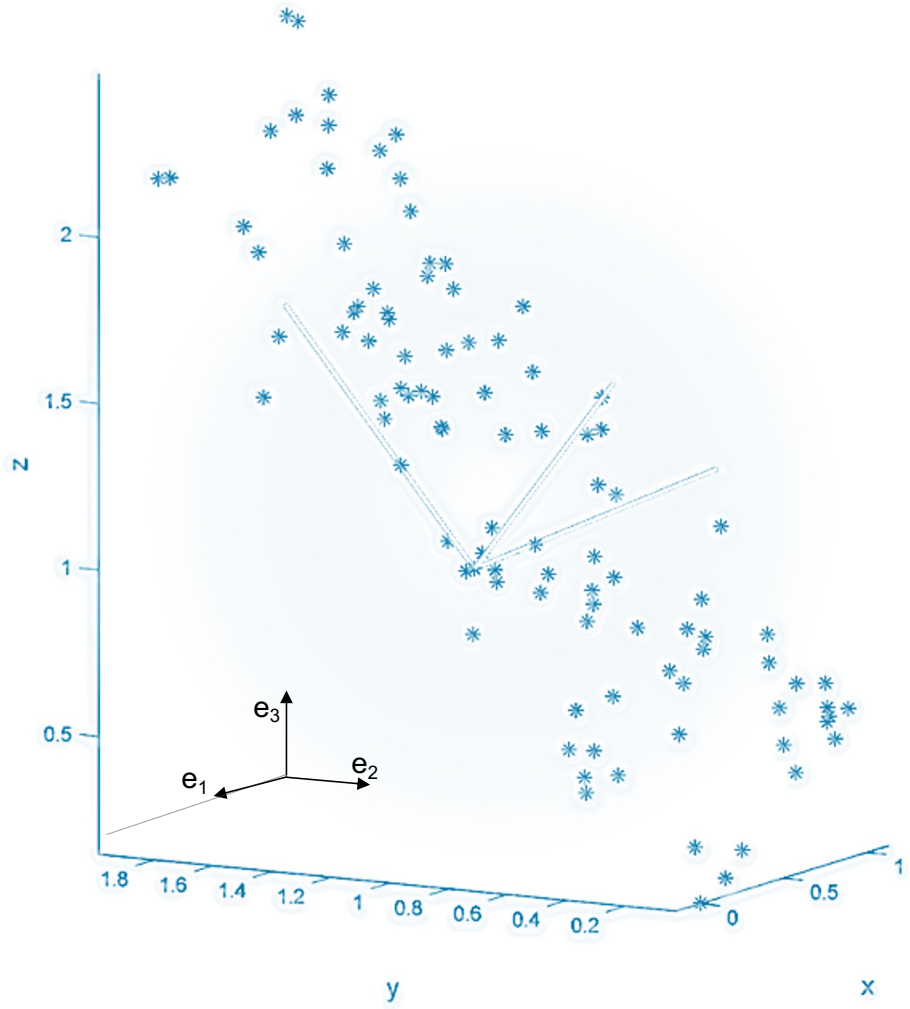




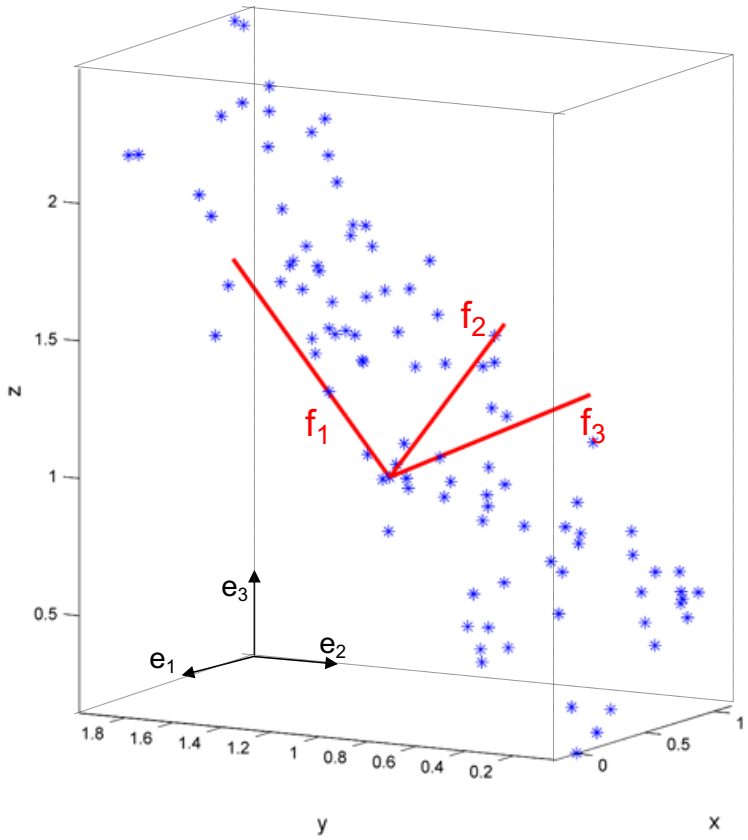
El procesamiento paralelo del Transformer impulsa modelos generativos capaces de crear contenido y comprender lenguaje a gran escala.

NotebookL

Muestra de datos tridimensionales



Muestra de datos tridimensionales



EOF	% varianza explicada
1	71.8
2	26.2
3	2.0

-Cada vector de la nueva base de proyección se define como una combinación lineal de los vectores de la base original

$f1 = 0.076e_1 + 0.687e_2 + 0.723e_3$
$f2 = 0.938e_2 + 0.295e_2 + 0.182e_3$
$f3 = 0.338e_1 + 0.664e_2 + 0.666e_3$

f1= (0.076, 0.687, 0.723)
f2= (0.938, 0.295, 0.182)

PCA Análisis de componentes principales para compresión de imágenes



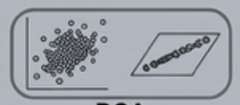


El Mapa de la Inteligencia Artificial: De los Algoritmos Clásicos a la Era Generativa

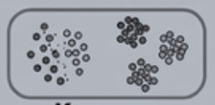
Paradigma Principal: Aprendizaje Clásico

APRENDIZAJE NO SUPERVISADO

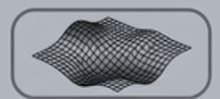
Explora Patrones Ocultos



PCA
Dimension Reduction



K-means
Clustering



SOM
Self-Organizing Maps

Buscan patrones ocultos sin etiquetas, simplifican dimensiones y agrupan datos.

APRENDIZAJE SUPERVISADO

Usa Datos Etiquetados



GLM
Modelos Lineales



KNN
Vecinos Cercanos



SVM
Máquinas de Soporte



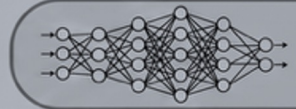
Boost
Gradient Boosting

Aprenden de ejemplos con etiquetes para clasificar o predecir resultados.

Evolución a Redes Neuronales y Aprendizaje Profundo

ANN
Redes Neuronales Artificiales





DNN
Redes Profundas

Evolución de redes simples a múltiples capas para procesar información compleja.

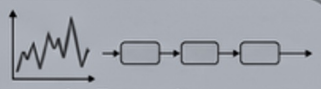
Arquitecturas Especializadas

CNN



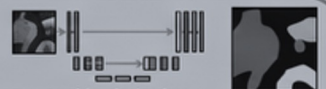
Visión por Computadora

LSTM



Secuencias Temporales

U-Net



Segmentación de Imágenes

Arquitecturas diseñadas para tipos de datos especificos como imágenes y secuencias.

Revolución de los Transformers y IA Generativa

TRANSFORMERS



LLM
Modelos de Lenguaje Masivos



GPT
Generative Pre-trained Transformer

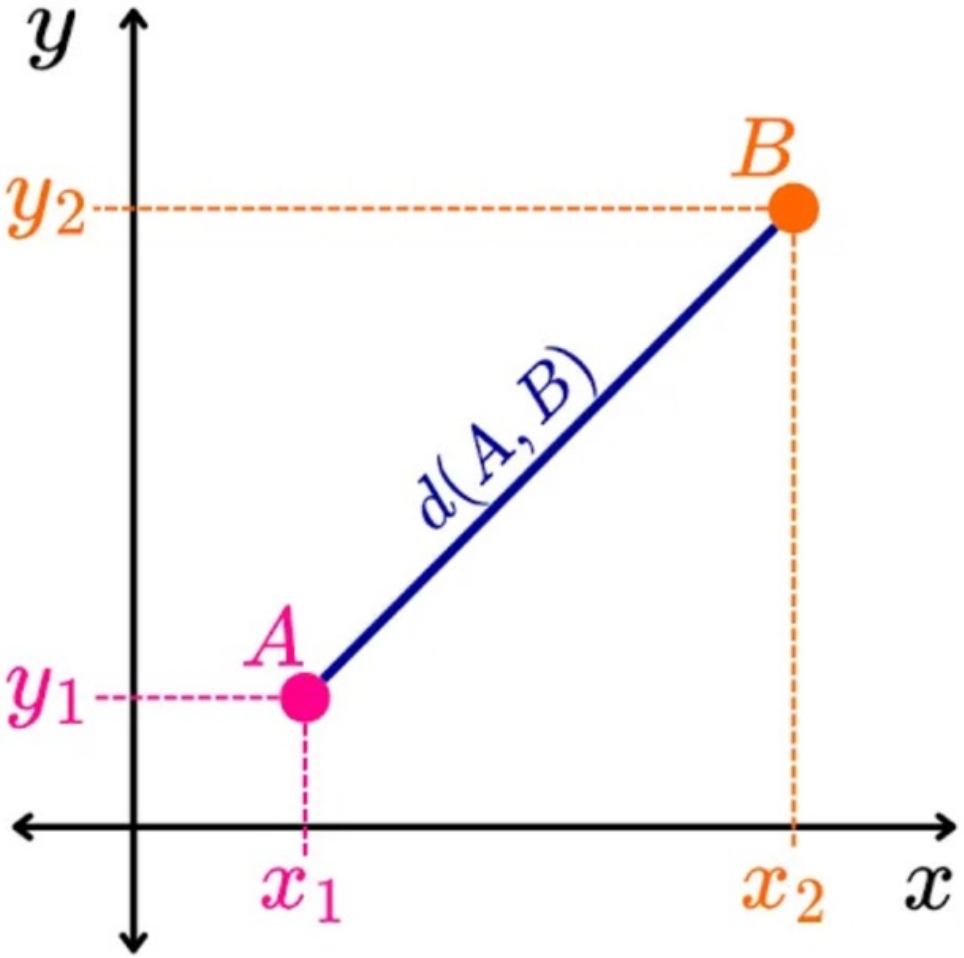




El procesamiento paralelo del Transformer impulsa modelos generativos capaces de crear contenido y comprender lenguaje a gran escala.

NotebookL

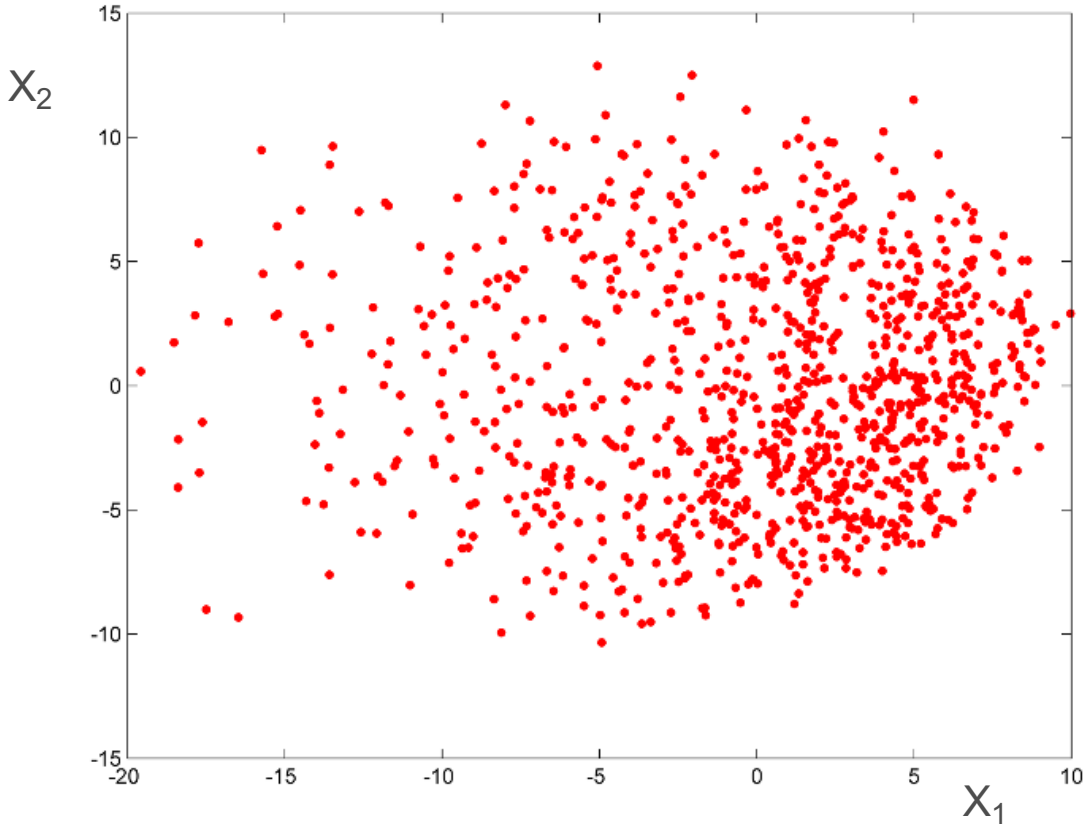
Distancia



$$d(A,B) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

$\{x_1, x_2, \ldots, x_N\}$ *N* datos

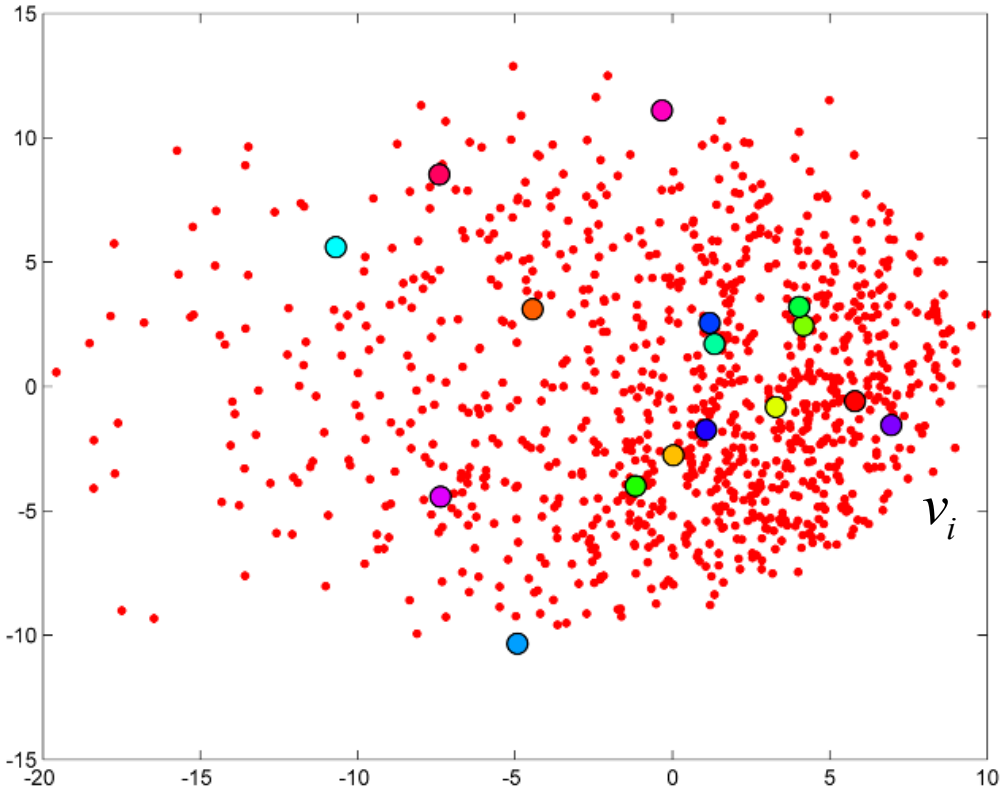
$\{v_1^0, \ldots, v_M^0\}$ *M* centroides ó prototipos



K-Medias

Muestra de datos bidimensionales

Objetivo: 16 grupos – Inicialización aletoria $\{v_1^0, v_2^0, ..., v_M^0\}$



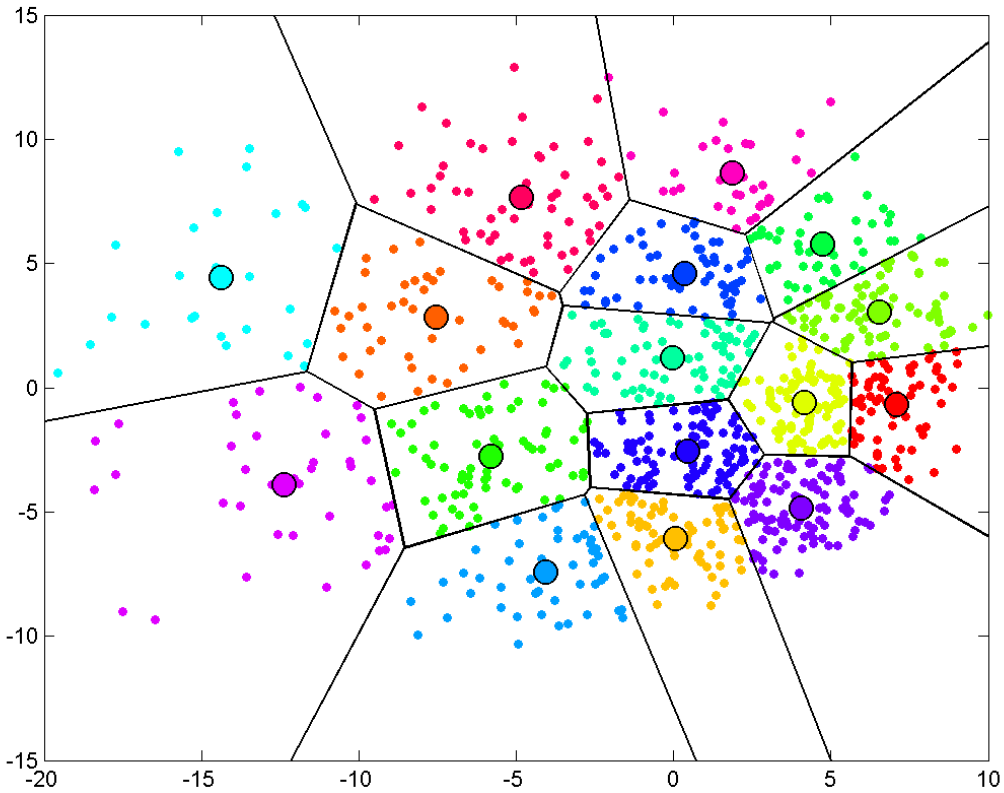
En la iteración *1*

x_i ⟶ Se asigna al grupo *j*

$$j = \min\left\{\left\|x_i - v_j\right\|, j = 1,..,M\right\}$$

⟶ Se actualiza el grupo *j* a partir de la media de todos los datos correspondientes a ese grupo

$$v_j^{r+1} = \sum_{x_i \in C_j} x_i / n_j$$



Pasa a la acción



Las 10 más populares en España hoy



Documentales



Anatomía de un Recomendador: Cómo el Machine Learning Predice tus Gustos

Fase 1: El Insumo de Datos (Aprendizaje No Supervisado)

Aprendizaje No Supervisado: Patrones sin Etiquetas

El sistema no recibe instrucciones sobre qué es 'acción' o 'jesz'; en su lugar, analiza el historial de consumo mosivo para descubrir grupos naturales de contenido y usuarios por el mismo.



El Historial como Variable de Entrada

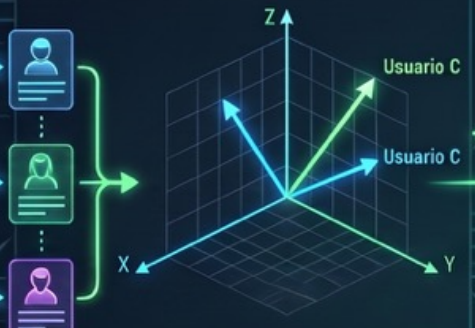
Cada interacción (clicc, tiempo de permanencia, saltos de canción) se convierta en un punto de detos que alimanta el modelo para construir el perfil del usuario.



Fase 2: Representación Matemática (Embeddings y Vectores)

De Gustos a Vectores (Embeddings)

El historial de un usuario se traduce a un 'embedding': una lista de números que representa su posición en un espacio de miles de dimensiones conceptuales.



Dimensiones de Afinidad

En este espacio multidimensional, cada eje puede representar una característica abstracta (ej. "ritmo frenético" o "melancolla") aprendida automáticamente por la red.

Fase 3: Cálculo de Similitud (Midiendo Distancias)

La Distancia es la Clave

La similitud entre usuarios se mide matemáticamente: a menor distancia geométrica entre sus vectores en el espacio, mayoras son las probabilidades de que compartan gustos.



El Producto Punto como Métrica

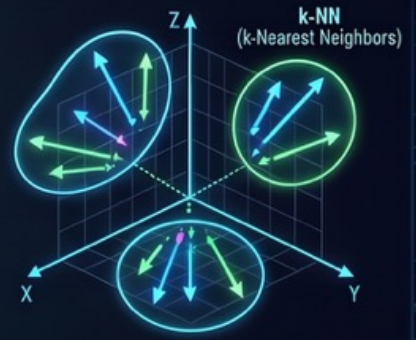
$$A \cdot B = |A||B| \cos(\theta)$$

Geométricamente, el producto punto permite medir qué tan alnieados están dos vectores; si apuntan en direcciones similares, el sistema detecta una alta correlación de preferencias.

Fase 4: Agrupación y Predicción (Clustering)

Clustering de Usuarios por Cercanía

Algoritmos como k-NN (k-Nearest Neighbors) agrupan a los usuarios basandose en sus vocinos más proximos en el mapa de datos.



Recomendación por Comportamiento Espajo

Si el Usuario A y el Usuario B están 'corca' matemáticamente, y el Usuario A disfrota de un contenido que el Usuario B ailn no ha visto, el sistema lo recomienda automáticamente.



Aspecto	Programación Tradicional (Basada en Reglas)	Machine Learning (Sistemas de Recomendación)
Lógica	Si género = 'Rock', recomendar 'Rock'.	Encuentra patrones ocultos en el historial.
Atributos	Etiquetas manuales (Metadatos).	Dimensiones aprendidas (Embeddings).
Escalabilidad	Limitada por la capacidad humana de etiquetar.	Automática sobre millones de usuarios y contenidos.

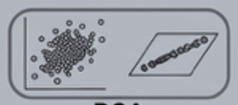
NotebookLM

El Mapa de la Inteligencia Artificial: De los Algoritmos Clásicos a la Era Generativa

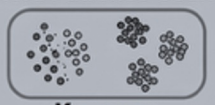
Paradigma Principal: Aprendizaje Clásico

APRENDIZAJE NO SUPERVISADO

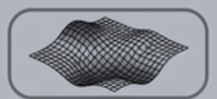
Explora Patrones Ocultos



PCA
Dimension Reduction



K-means
Clustering



SOM
Self-Organizing Maps

Buscan patrones ocultos sin etiquetas, simplifican dimensiones y agrupan datos.

APRENDIZAJE SUPERVISADO

Usa Datos Etiquetados



GLM
Modelos Lineales



KNN
Vecinos Cercanos



SVM
Máquinas de Soporte



Boost
Gradient Boosting

Aprenden de ejemplos con etiquetes para clasificar o predecir resultados.

Evolución a Redes Neuronales y Aprendizaje Profundo

ANN
Redes Neuronales Artificiales





DNN
Redes Profundas

Evolución de redes simples a múltiples capas para procesar información compleja.

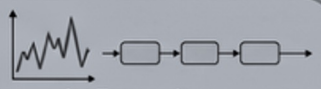
Arquitecturas Especializadas

CNN



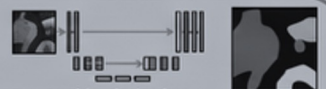
Visión por Computadora

LSTM



Secuencias Temporales

U-Net



Segmentación de Imágenes

Arquitecturas diseñadas para tipos de datos especificos como imágenes y secuencias.

Revolución de los Transformers y IA Generativa

TRANSFORMERS



LLM
Modelos de Lenguaje Masivos



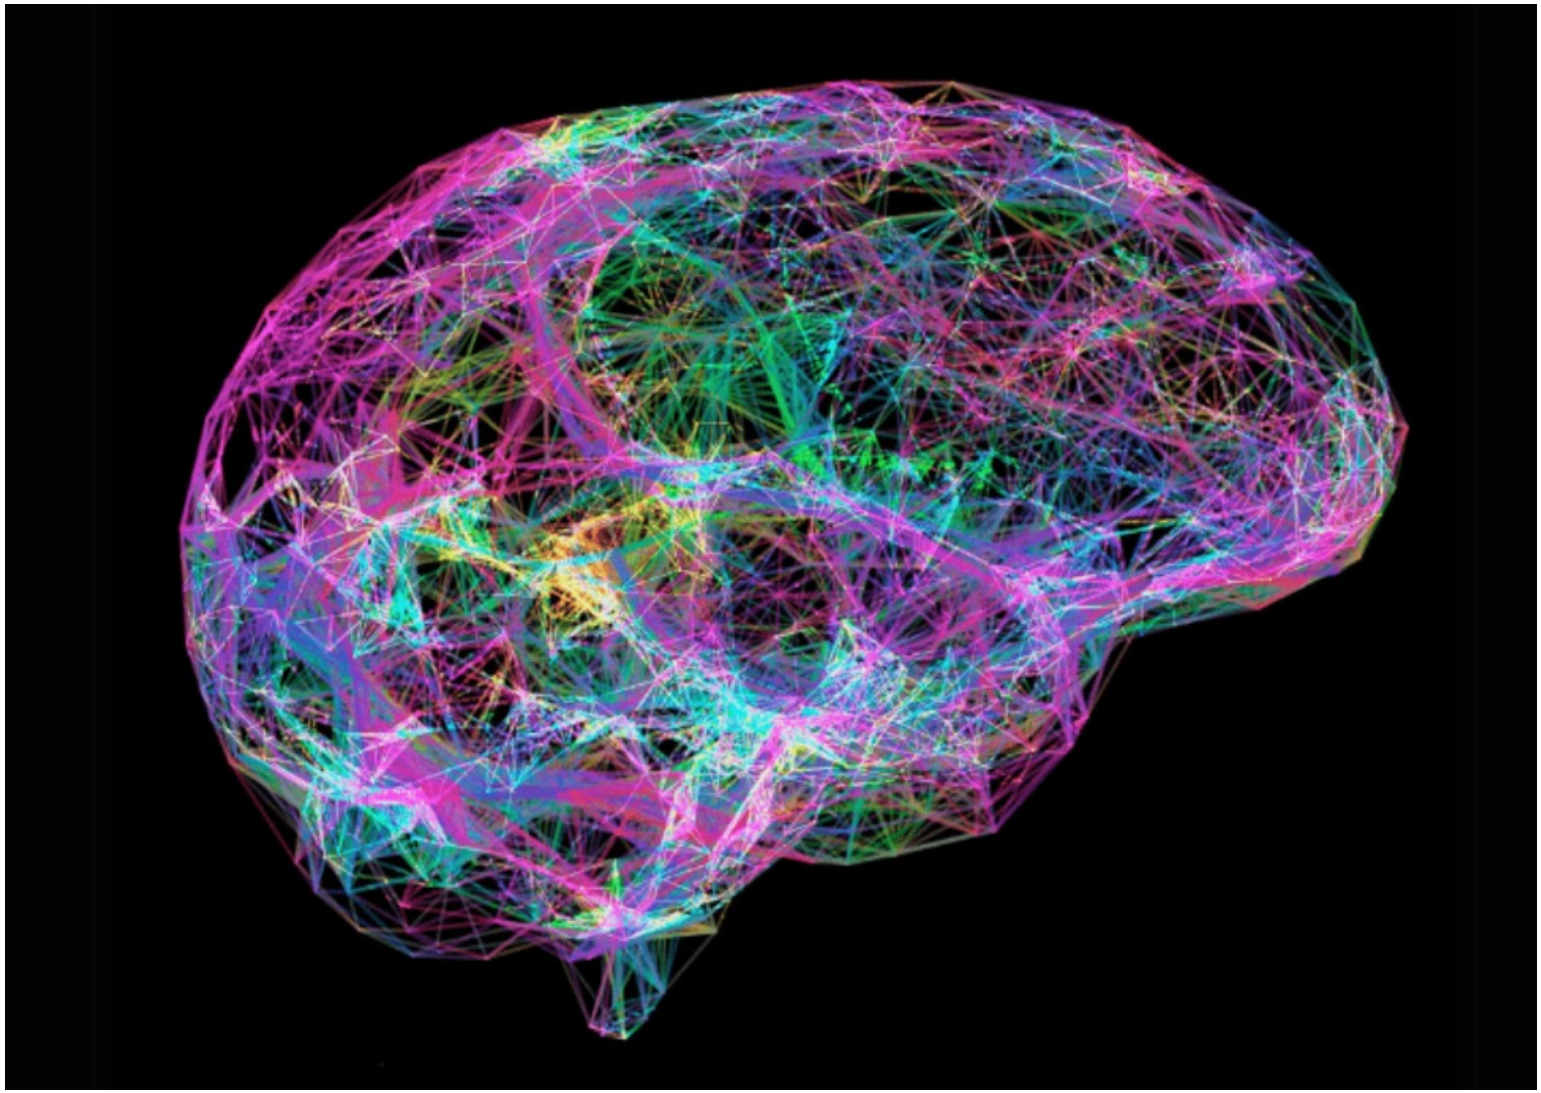
GPT
Generative Pre-trained Transformer

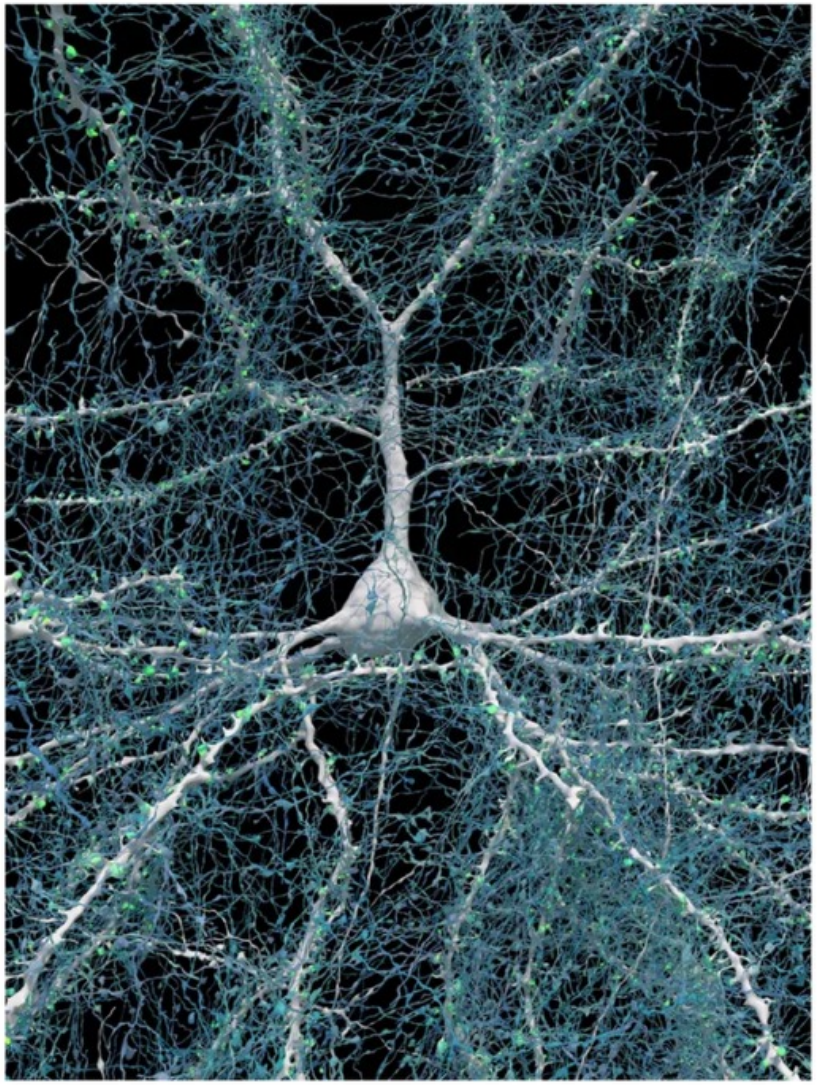




El procesamiento paralelo del Transformer impulsa modelos generativos capaces de crear contenido y comprender lenguaje a gran escala.

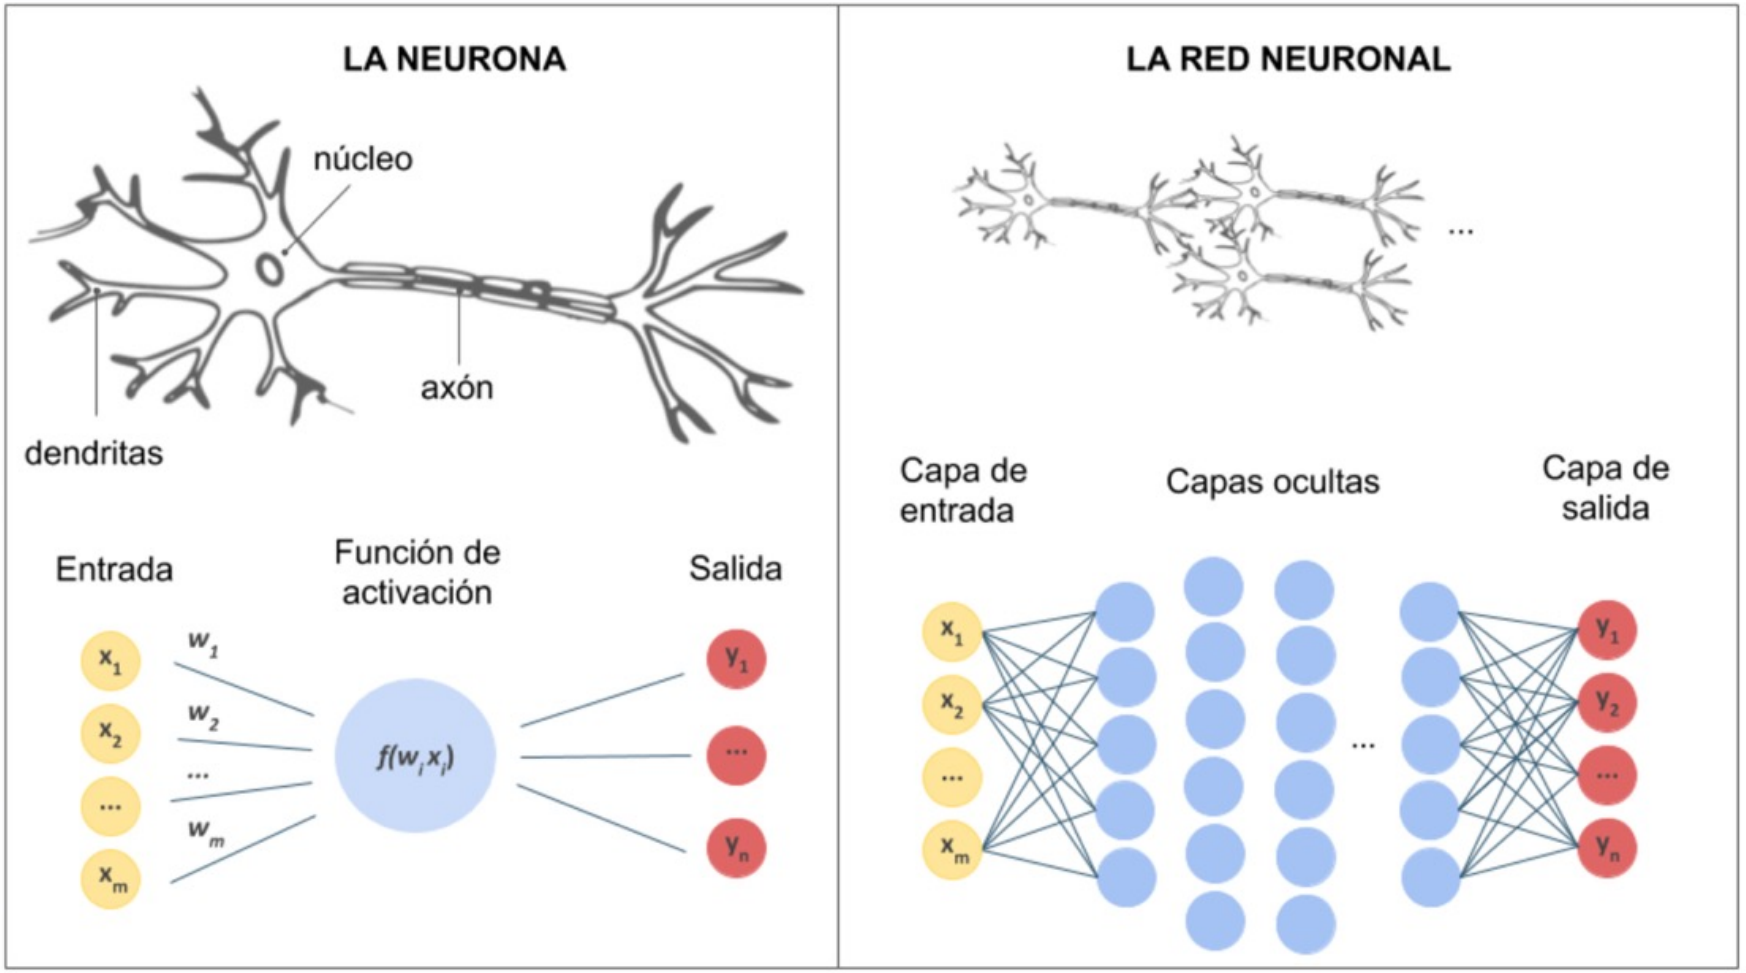
NotebookL





Una neurona (en blanco) con alrededor de 5,000 axones (azules). Las sinapsis son los destellos verdes.

- Estudio de Google Res. y Harvard Univ (2024)
- 1 mm3 de cerebro
- 57000 neuronas
- 150 millones de conexiones
- 1.4 millones Gb


LA NEURONA
núcleo
axón
dendritas
Entrada
Función de activación
Salida
x_1
x_2
...
x_m
w_1
w_2
...
w_m
$f(w_i x_i)$
y_1
...
y_n
LA RED NEURONAL
...
Capa de entrada
Capas ocultas
Capa de salida
x_1
x_2
...
x_m
...
y_1
y_2
...
y_n

Arquitectura ANN(2, b, c)

** Entradas (a) fijadas en 2 (x_1, x_2)*

Ocultas (b): 2

Salidas (c): 1

Ecuaciones Expandidas (Valores en Tiempo Real)

$$y_1 = \sigma\Big(-1.5\sigma(0.6x_1 + 3.0x_2 + 5.0) + 2.4\sigma(0.6x_1 + 0.7x_2 + 0.0) + 0.0\Big)$$

* Las superficies 3D inferiores grafican cada una de estas funciones resultantes.

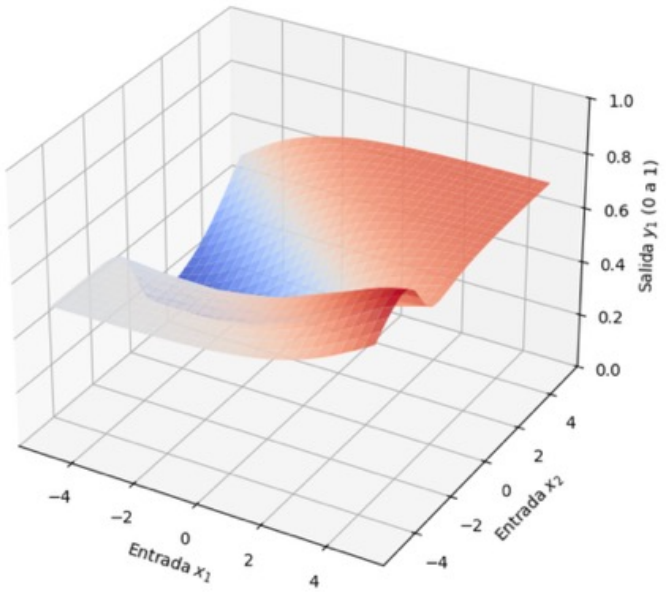
Pesos Capa Oculta (w) y Sesgos (b1)

Peso w_11:	0.60	Peso w_12:	3.00	Sesgo b1_1:	5.00
Peso w_21:	0.60	Peso w_22:	0.70	Sesgo b1_2:	0.00

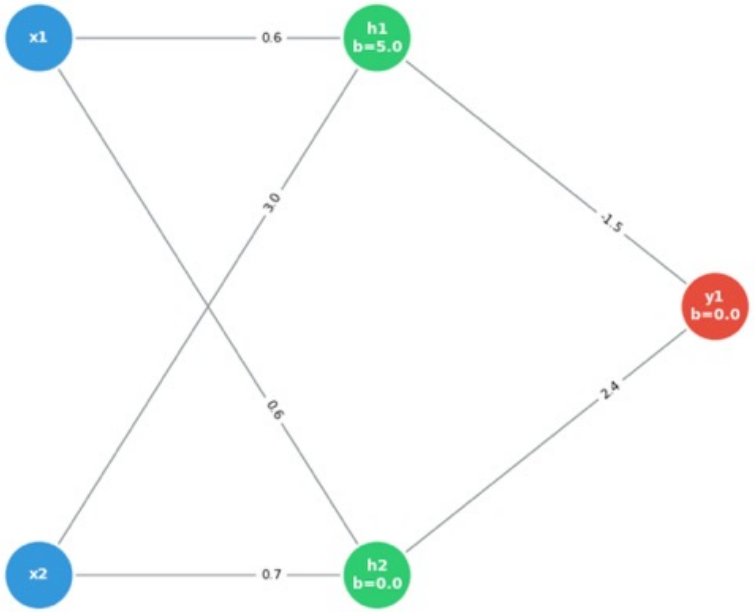
Pesos Capa Salida (v) y Sesgos (b2)

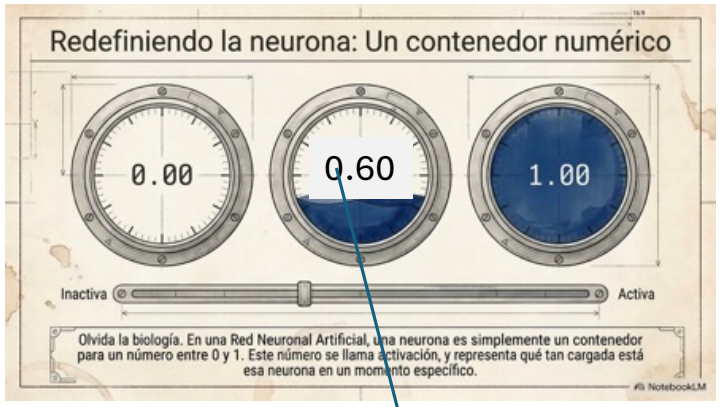
Peso v_11:	−1.50	Peso v_12:	2.40	Sesgo b2_1:	0.00

Superficie de Decisión (y_1)

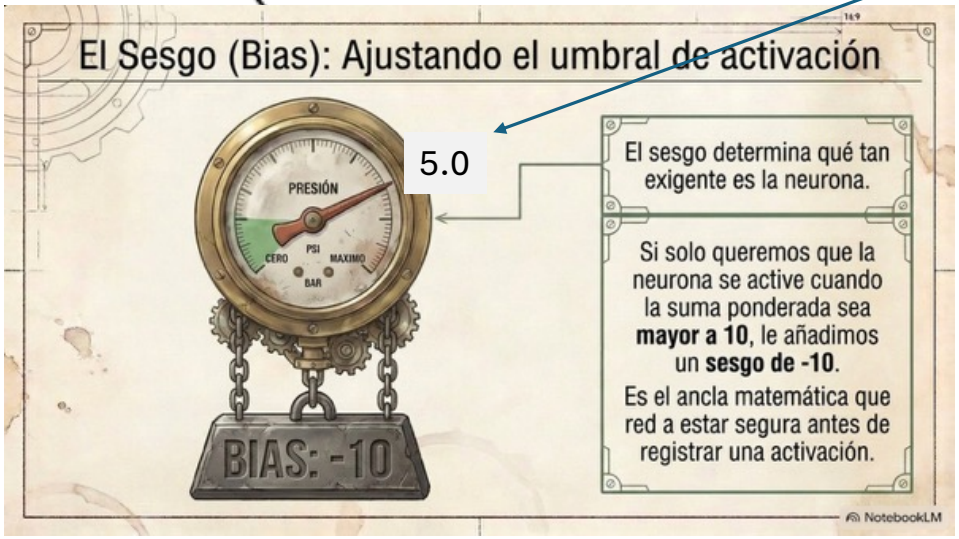


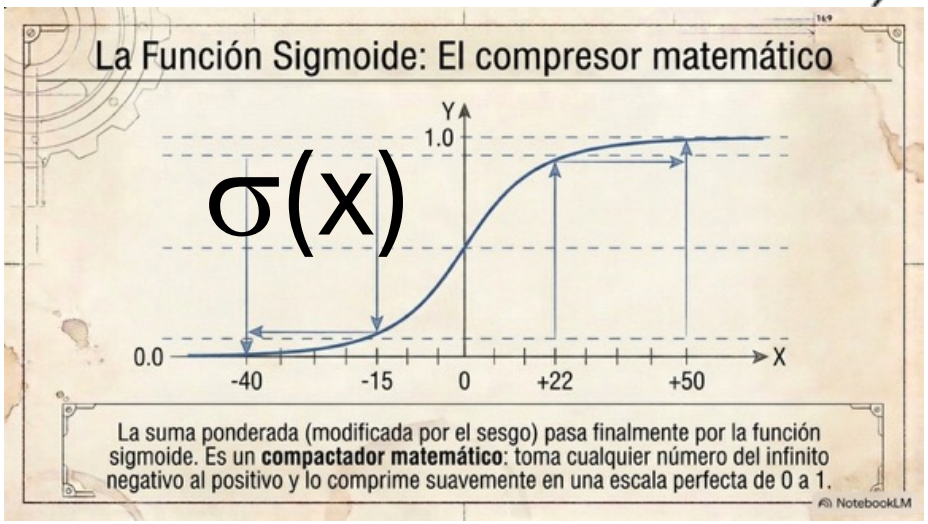
Arquitectura ANN(2, 2, 1)





$$y_1 = \sigma\Big(-1.5\sigma(0.6x_1 + 3.0x_2 + 5.0) + 2.4\sigma(0.6x_1 + 0.7x_2 + 0.0) + 0.0\Big)$$







ANN(2,3,1).ipnyb



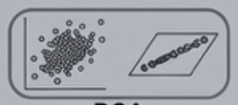
TrainingANN.ipnyb

El Mapa de la Inteligencia Artificial: De los Algoritmos Clásicos a la Era Generativa

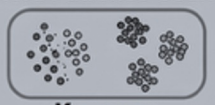
Paradigma Principal: Aprendizaje Clásico

APRENDIZAJE NO SUPERVISADO

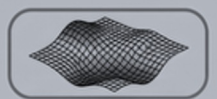
Explora Patrones Ocultos



PCA
Dimension Reduction



K-means
Clustering



SOM
Self-Organizing Maps

Buscan patrones ocultos sin etiquetas, simplifican dimensiones y agrupan datos.

APRENDIZAJE SUPERVISADO

Usa Datos Etiquetados



GLM
Modelos Lineales



KNN
Vecinos Cercanos



SVM
Máquinas de Soporte



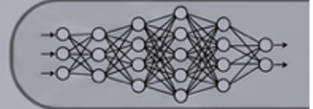
Boost
Gradient Boosting

Aprenden de ejemplos con etiquetes para clasificar o predecir resultados.

Evolución a Redes Neuronales y Aprendizaje Profundo

ANN
Redes Neuronales Artificiales





DNN
Redes Profundas

Evolución de redes simples a múltiples capas para procesar información compleja.

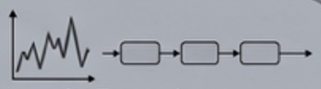
Arquitecturas Especializadas

CNN



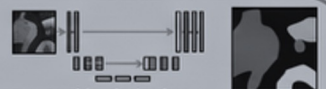
Visión por Computadora

LSTM



Secuencias Temporales

U-Net



Segmentación de Imágenes

Arquitecturas diseñadas para tipos de datos especificos como imágenes y secuencias.

Revolución de los Transformers y IA Generativa

TRANSFORMERS



LLM
Modelos de Lenguaje Masivos



GPT
Generative Pre-trained Transformer





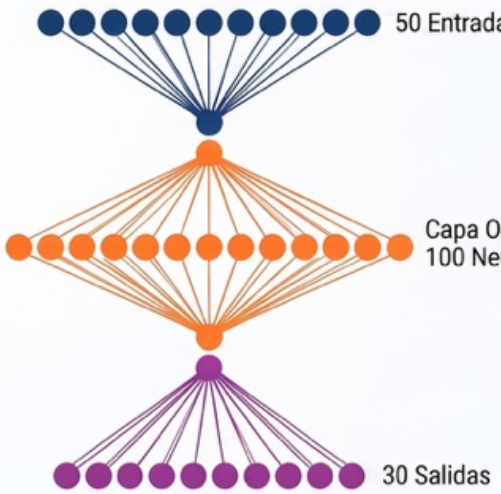
El procesamiento paralelo del Transformer impulsa modelos generativos capaces de crear contenido y comprender lenguaje a gran escala.

NotebookL

Comparativa de Arquitecturas: Redes Neuronales de 3 vs. 4 Capas

Una red neuronal artificial es una función matemática inspirada en el cerebro que procesa datos a través de capas de neuronas. Mientras que las redes más simples manejan abstracciones básicas, las redes más profundas (con más capas ocultas) pueden identificar patrones jerárquicos complejos, aumentando su precisión a cambio de una mayor demanda computacional.

ANN Simple (50, 100, 30)



Jerarquía de Abstracción

La red de 4 capas permite descomponer problemas en subcomponentes más detallados que la de 3.

Definición: Capas Ocultas (Hidden Layers)
Espacio donde la red extrae características; más capas equivalen a una mayor profundidad de razonamiento.

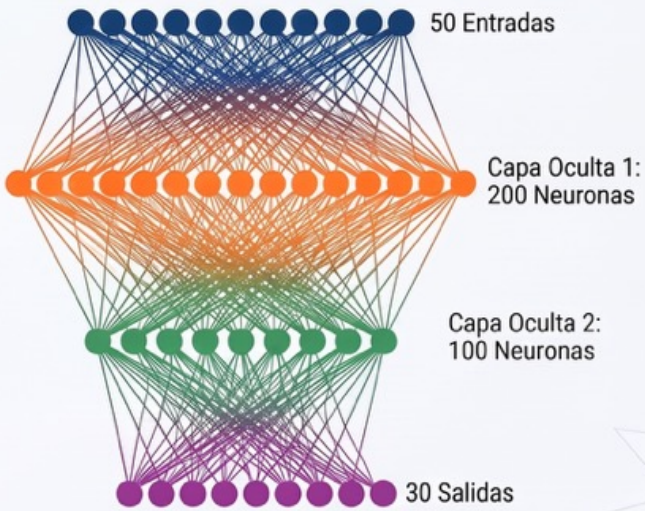
Parámetros y Complejidad

Explosión de Pesos y Sesgos

La red de 4 capas posee significativamente más "perillas" o parámetros ajustables para aprender.

	Red 3 Capas (Simple)	Red 4 Capas (Profunda)
Capas Ocultas:	Capas Ocultas: 1 (100 neuronas)	Capas Ocultas: 2 (200 y 100 neuronas)
Total de Pesos: conexiones	8,000	33,000
Capacidad:	Patrones básicos	**Capacidad:** Patrones jerárquicos complejos

ANN Profunda (50, 200, 100, 30)



NotebookLM

¿Cómo 'Piensa' una IA? El Viaje del Reconocimiento de un Dígito

Capa de Entrada: La Descomposición Visual



De Imagen a 784 Neuronas de Entrada: Una imagen de 28x28 pixeles se descompene en una cuacricula donde cada píxel tiene un valor entre 0 (negro) y 1 (blanca).

Activación de Neuronas
El brillo de cada píxel determina la "activación" de cada una de los T04 naurocas inicialos que alimentan la red.

Capas Ocultas: La Escalera de Abstracción

Capa Oculta 1: Detección de Bordes
En esta etapa, la red buaca patronos básicos, como pequeños bordes individuales en regiones especificas de la imagen.

Capa Oculta 2: Subcomponentes y Formas
Las neuronas de esta capa contiinan los bordes detectados anteriormente para identificar patrones complejes como bucios, aros o imeas largas.

Pesos y Sesgos (El Filtro Inteligente)
Cada conexión tiene un "peso" que indica qué pixeles o bordos importan más para ectivar la siguiente neurona.

Capa Oculta 2: Subcomponentes y Formas
Las neuronas de esta capa combinan los bordos datectaalos anteriormente para identificar patronas complejos como bocios, aros u lineas largas.

Capa de Salida: La Decisión Final

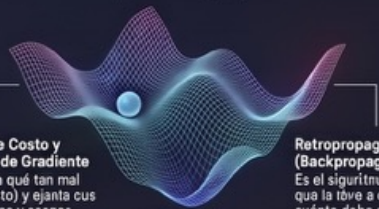
0 1 2 **3** 4 5 6 7 8 9

Clasificación del Digito
La capa final contiene 10 neuronas, cada una representando un digito del 0 al 9.

3

La Neurona más Brillante Gena
El sidlema claalFny la imagen basándose en auál de las 10 neuronas de salida tiene la mayor activación (se la más "briliante").

El Proceso de Aprendizaje (Detrás de Escena)



Funciön de Costo y Descenso de Gradiente
La red mida qué tan mal la niss (costo) y ejanta cus 13.000 pesos y secgos para "tugar la calina" havie al error mínimo.

Retropropagación (Backpropagation)
Es el siguritnul central qua la tòve a culia puso cuánto debe cambiar para reajorar la previsión de la red an el sigurante intanto.

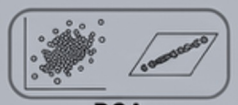
NotebookLM

El Mapa de la Inteligencia Artificial: De los Algoritmos Clásicos a la Era Generativa

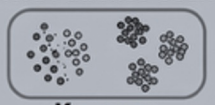
Paradigma Principal: Aprendizaje Clásico

APRENDIZAJE NO SUPERVISADO

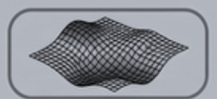
Explora Patrones Ocultos



PCA
Dimension Reduction



K-means
Clustering



SOM
Self-Organizing Maps

Buscan patrones ocultos sin etiquetas, simplifican dimensiones y agrupan datos.

APRENDIZAJE SUPERVISADO

Usa Datos Etiquetados



GLM
Modelos Lineales



KNN
Vecinos Cercanos



SVM
Máquinas de Soporte



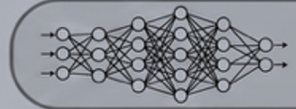
Boost
Gradient Boosting

Aprenden de ejemplos con etiquetes para clasificar o predecir resultados.

Evolución a Redes Neuronales y Aprendizaje Profundo

ANN
Redes Neuronales Artificiales





DNN
Redes Profundas

Evolución de redes simples a múltiples capas para procesar información compleja.

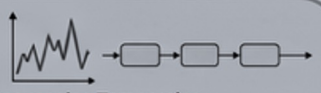
Arquitecturas Especializadas

CNN



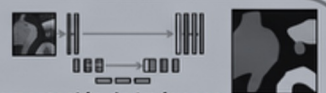
visión por Computadora

LSTM



Secuencias Temporales

U-Net



Segmentación de Imágenes

Arquitecturas diseñadas para tipos de datos especificos como imágenes y secuencias.

Revolución de los Transformers y IA Generativa

TRANSFORMERS



LLM
Modelos de Lenguaje Masivos



GPT
Generative Pre-trained Transformer

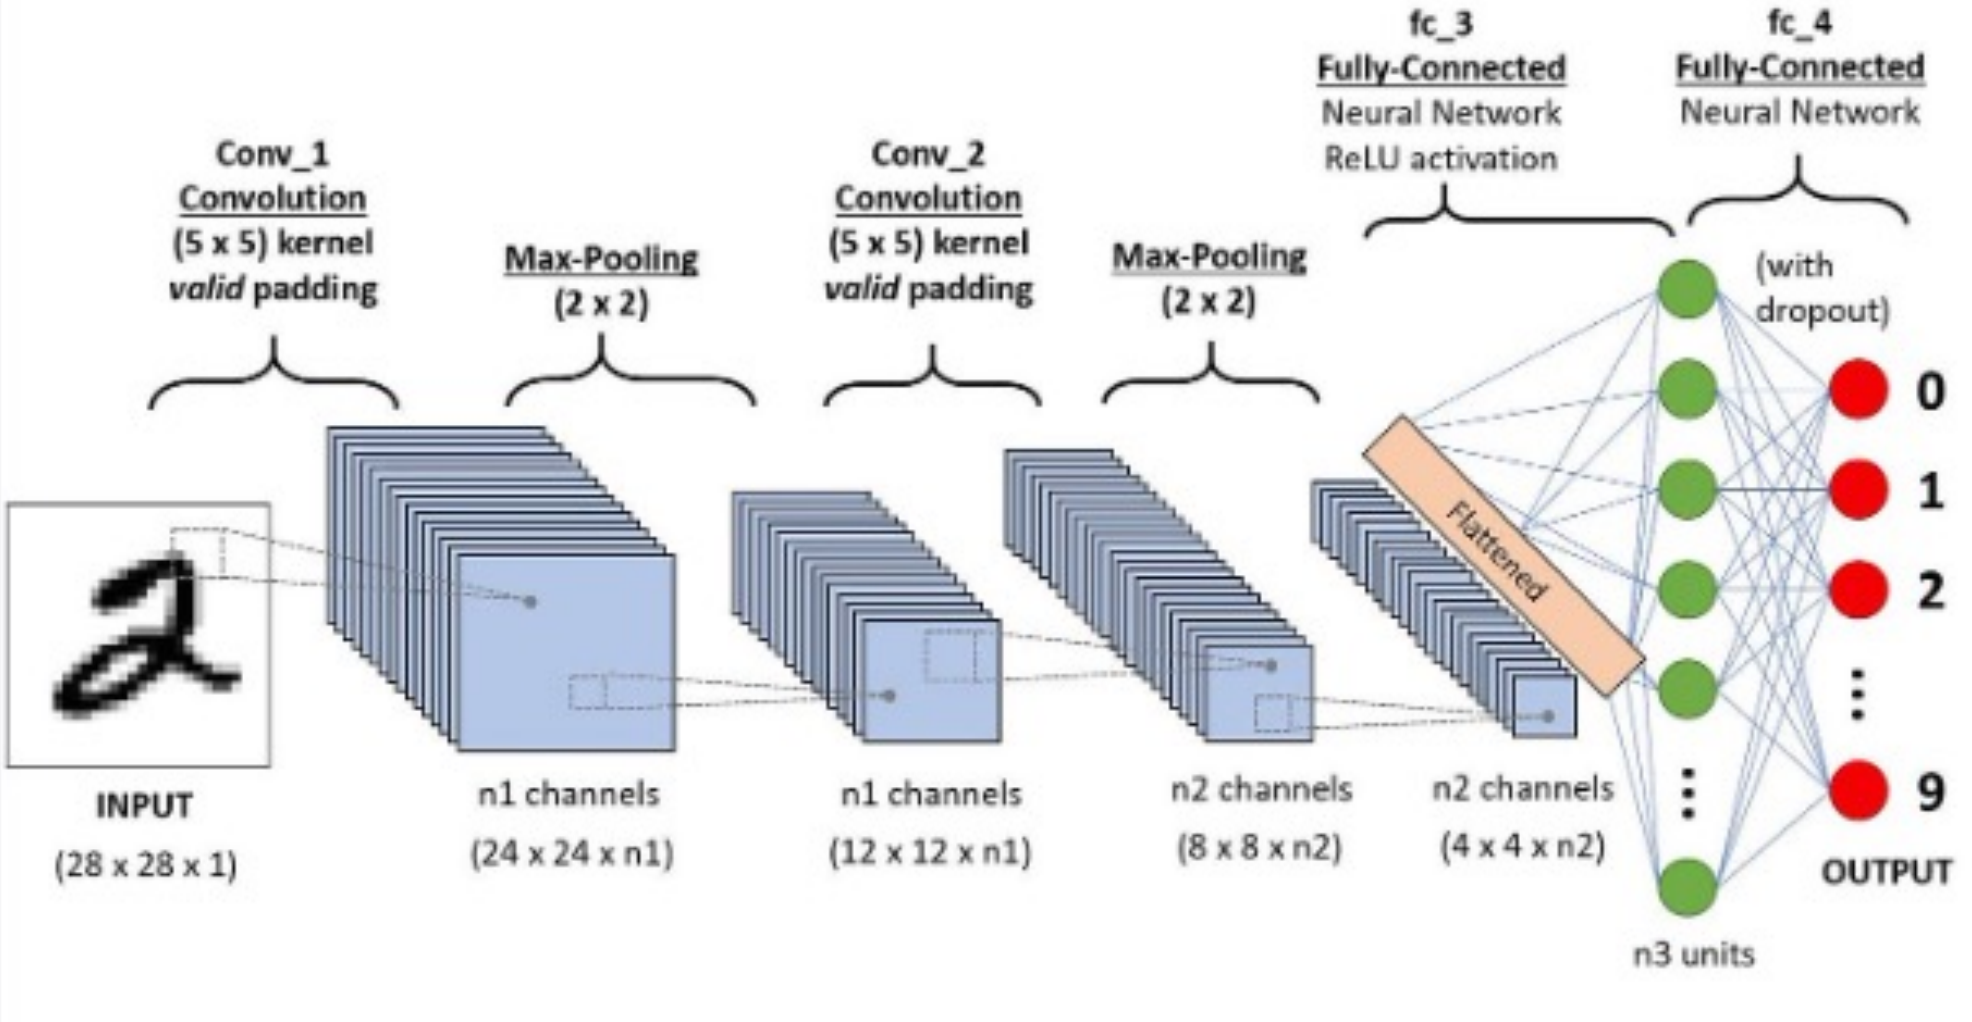




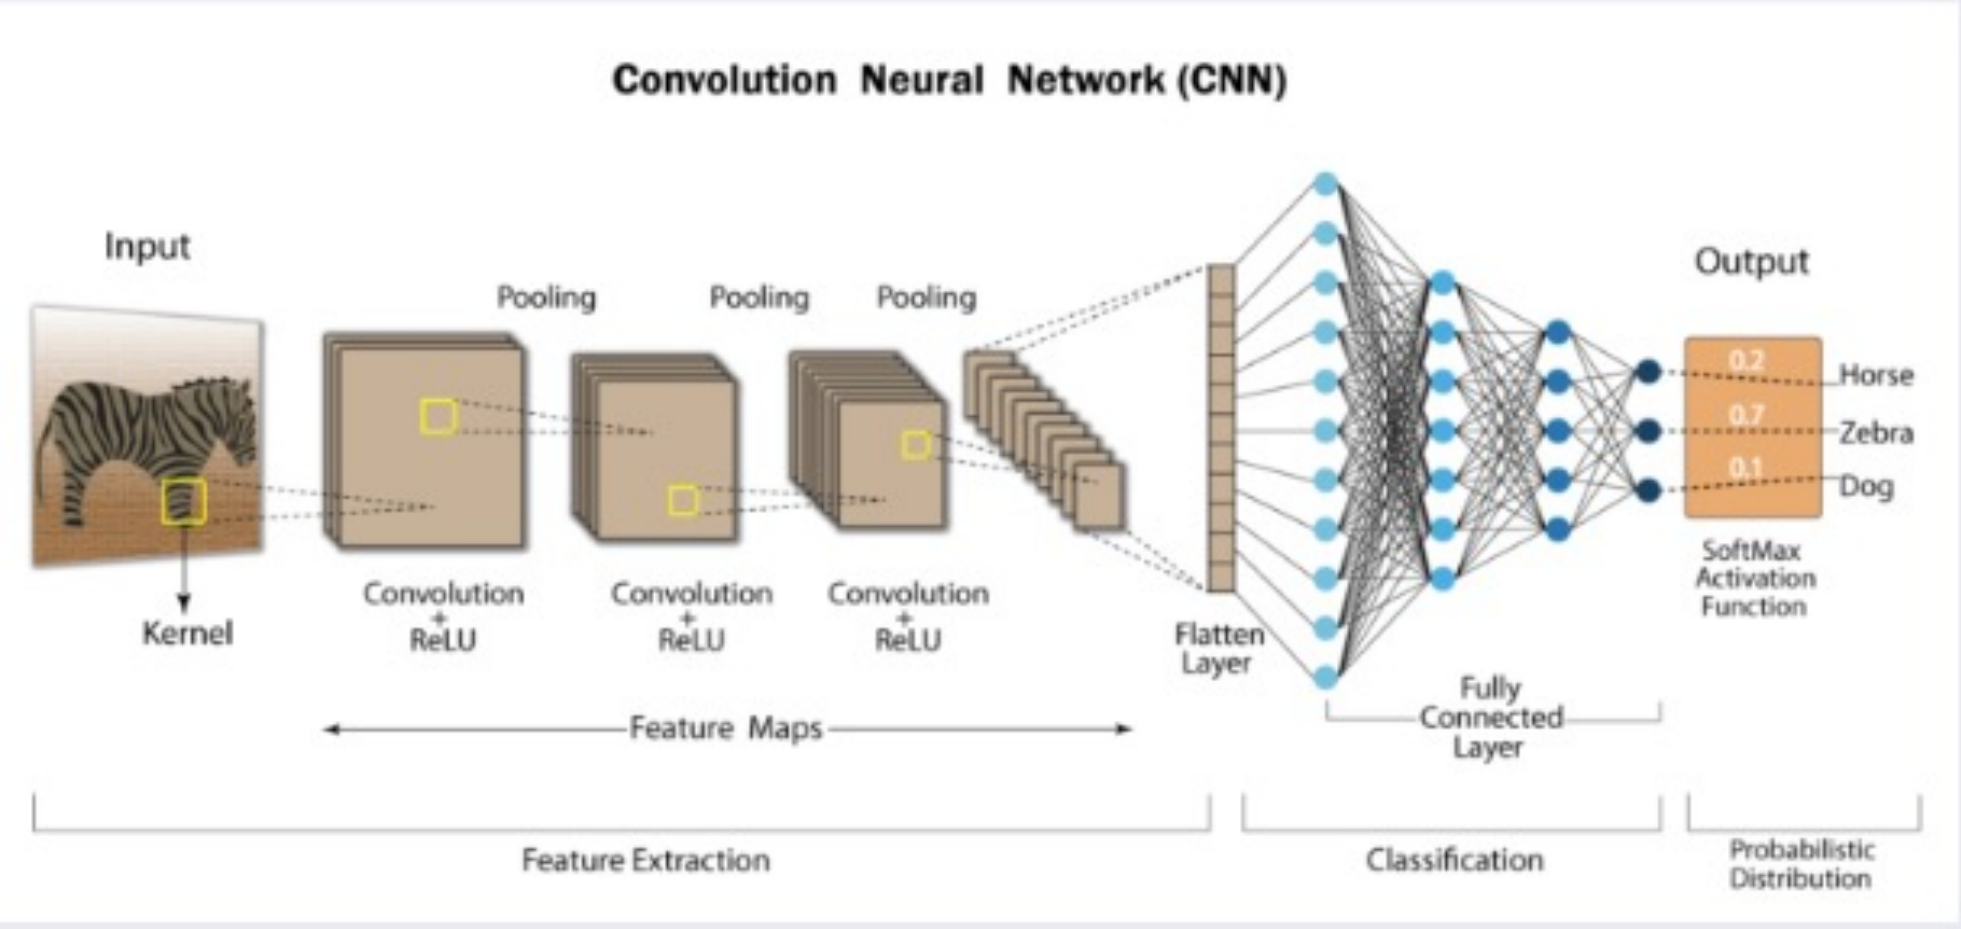
El procesamiento paralelo del Transformer impulsa modelos generativos capaces de crear contenido y comprender lenguaje a gran escala.

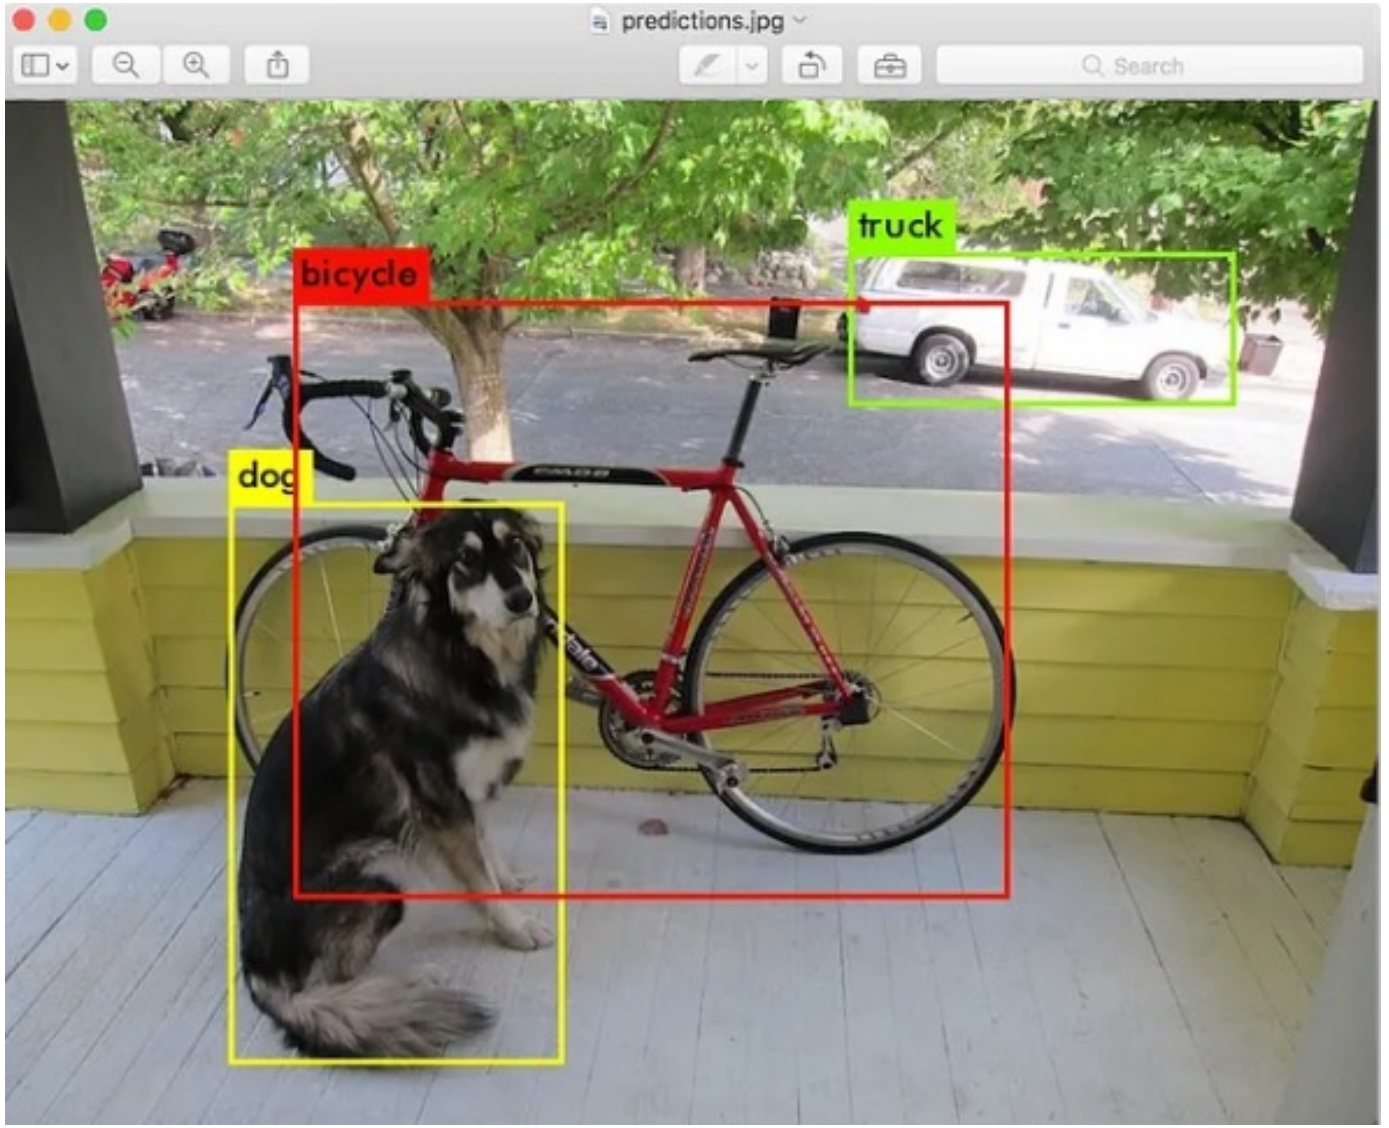
NotebookL

CNN: Redes Neuronales Convolucionales



CNN: Redes Neuronales Convolucionales



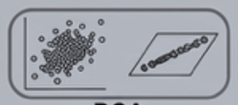

predictions.jpg
Search
truck
bicycle
dog

El Mapa de la Inteligencia Artificial: De los Algoritmos Clásicos a la Era Generativa

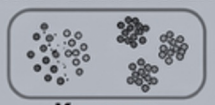
Paradigma Principal: Aprendizaje Clásico

APRENDIZAJE NO SUPERVISADO

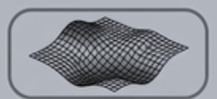
Explora Patrones Ocultos



PCA
Dimension Reduction



K-means
Clustering



SOM
Self-Organizing Maps

Buscan patrones ocultos sin etiquetas, simplifican dimensiones y agrupan datos.

APRENDIZAJE SUPERVISADO

Usa Datos Etiquetados



GLM
Modelos Lineales



KNN
Vecinos Cercanos



SVM
Máquinas de Soporte



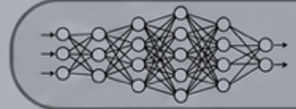
Boost
Gradient Boosting

Aprenden de ejemplos con etiquetes para clasificar o predecir resultados.

Evolución a Redes Neuronales y Aprendizaje Profundo

ANN
Redes Neuronales Artificiales





DNN
Redes Profundas

Evolución de redes simples a múltiples capas para procesar información compleja.

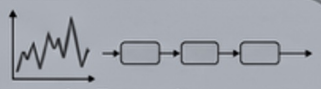
Arquitecturas Especializadas

CNN



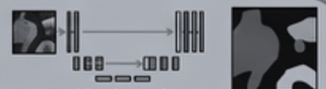
Visión por Computadora

LSTM



Secuencias Temporales

U-Net



Segmentación de Imágenes

Arquitecturas diseñadas para tipos de datos especificos como imágenes y secuencias.

Revolución de los Transformers y IA Generativa

TRANSFORMERS



LLM
Modelos de Lenguaje Masivos



GPT
Generative Pre-trained Transformer

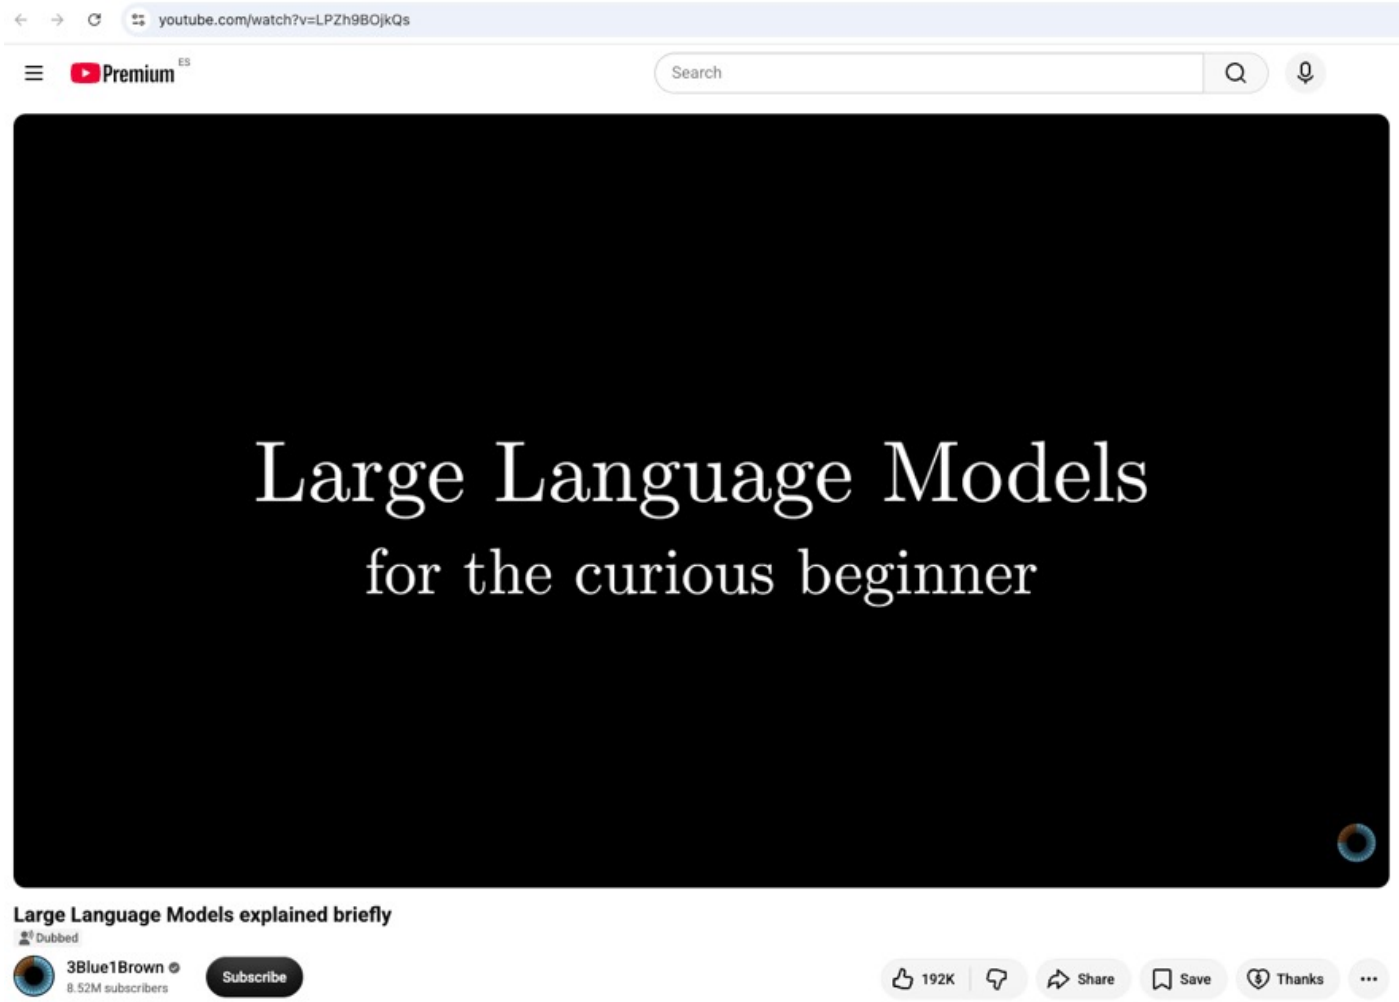




El procesamiento paralelo del Transformer impulsa modelos generativos capaces de crear contenido y comprender lenguaje a gran escala.

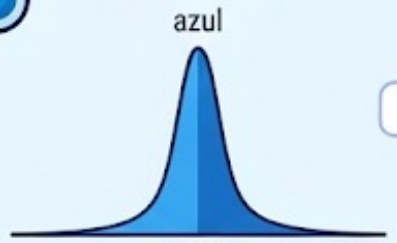
NotebookL

https://www.youtube.com/watch?v=LPZh9BOjkQs



EL PARÁMETRO TEMPERATURA EN UN LLM

BAJA TEMPERATURA (0.1 - 0.3)



Determinista y Preciso

Example Output:

El cielo es de color azul claro.

Más predecible, conservador.
Favorece las palabras más probables.
Ideal para hechos y código.

LLM INPUT

El cielo es de color...

0.1 1.5+

TEMPERATURA
(Temperature)

TEMPERATURA MEDIA (~0.7)



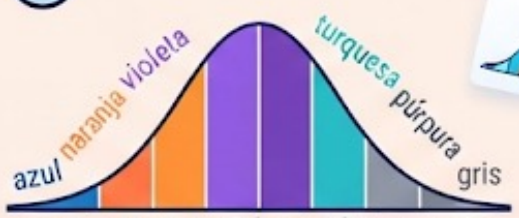
Equilibrado y Coherente

Example Output:

El cielo es de color azul brillante.

Equilibrio entre creatividad y realismo.
Respuestas naturales.
Uso general y chatbots.

ALTA TEMPERATURA (1.0 - 1.5+)



Creativo e Impredecible

Example Output:

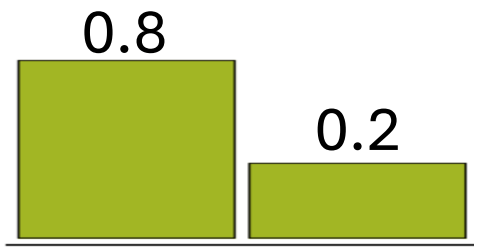
El cielo es de color púrpura vibrante con toques de rosa.

Más aleatorio, creativo, diverso. Puede generar respuestas únicas y menos lógicas.
Ideal para brainstorming y escritura creativa.

Método de Monte Carlo

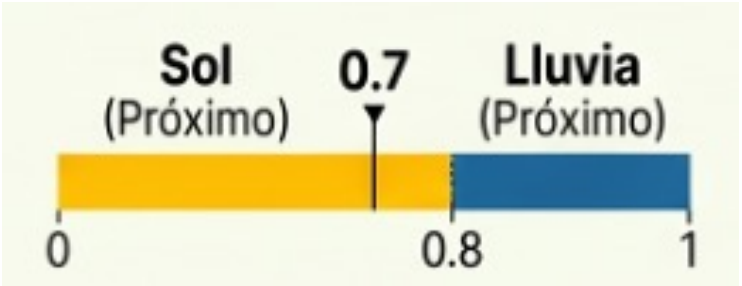


Se originó durante la Segunda Guerra Mundial en el Laboratorio Nacional de Los Álamos, creado por los científicos Stanislaw Ulam y John von Neumann. Lo desarrollaron para resolver problemas complejos de difusión de neutrones en el Proyecto Manhattan mediante el uso de muestreos aleatorios y probabilidad









Predicción del Clima: Cadenas de Markov y Simulaciones de Monte Carlo

El Modelo: La Cadena de Markov

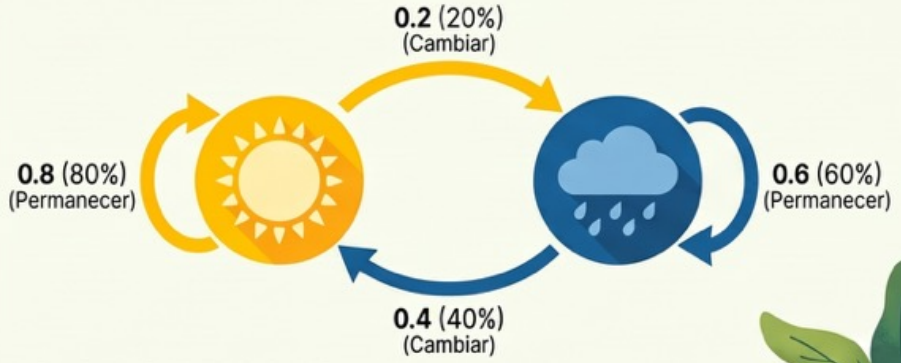
¿Qué es una Cadena de Markov?
Es un sistema que transita de un estado a otro (Sol o Lluvia) basándose en **reglas probabilísticas** donde el mañana solo **depende de hoy.**

Estados Discretos



Sol (S) **Lluvia (R)**

La Matriz de Transición



Reglas de Probabilidad de Transición: La matriz define las "reglas del juego" para el cambio de clima basado en datos históricos.

El Motor: Simulación de Monte Carlo Paso a Paso

1. Definir el Estado Inicial (X_0)





Sol (X_0 = 1, 0)

2. Generar un Número Aleatorio



0.7 (Ejemplo)

El ordenador genera un número entre 0 y 1.

3. Aplicar el Umbral de Decisión



Si hoy es **Sol** y el número es < **0.8**, mañana será **Sol.**

4. Repetir para Crear la Serie



El resultado de cada paso se convierte en el "hoy" del siguiente, generando una secuencia.

Resultados y Convergencia

Generación de Series de Tiempo



El resultado es una serie sintética que preserva las propiedades estadísticas del clima real.

Estabilización (Distribución Estacionaria)



Tras miles de simulaciones ($N \to \infty$), las probabilidades se estabilizan.

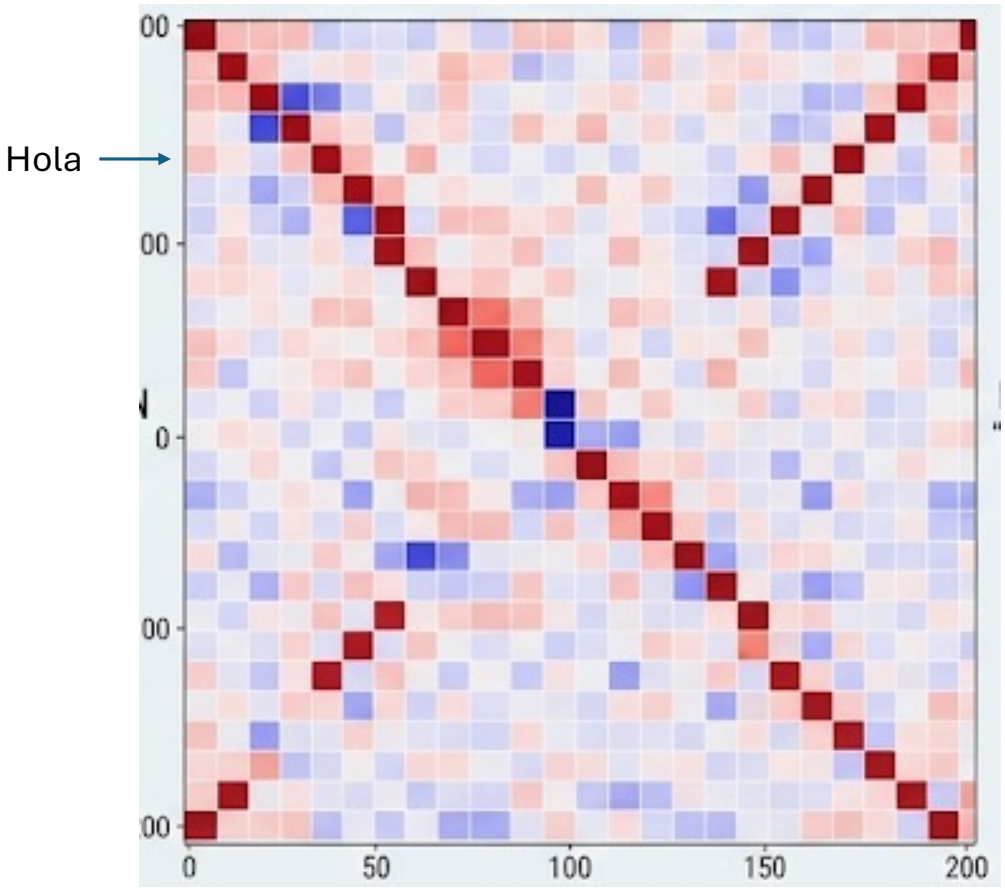
En este modelo, el **Sol** converge hacia el **68-70%** y la **Lluvia** hacia el **30-32%.**

NotebookLM



CadenaMarkov.ipnyb

... volviendo a los LLMs...

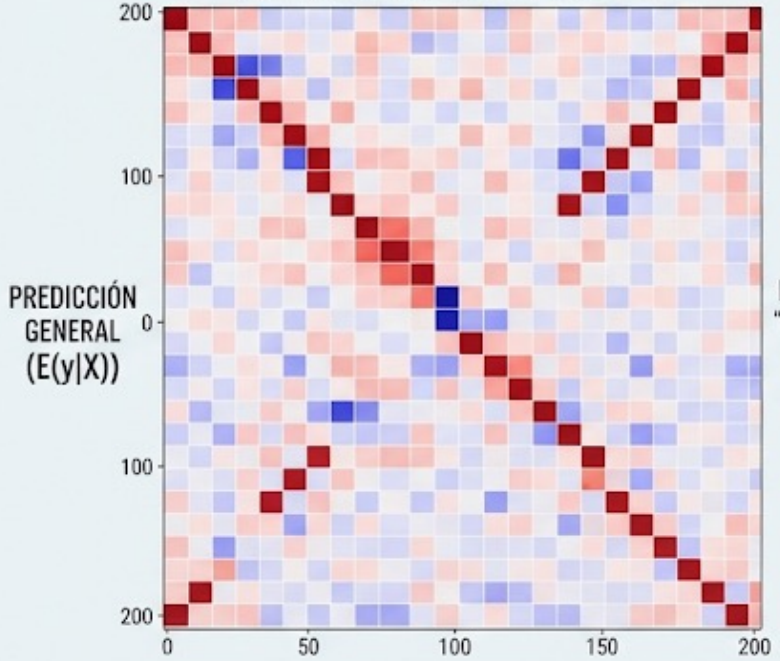


Matriz de pesos pre-entrenada con miles de millones de palabras (tokens) encadenadas

IMPACTO DEL CONTEXTO ADICIONAL EN LOS PESOS DE UN MODELO AUTORREGRESIVO LOGÍSTICO

1. PESOS BASE (SIN CONTEXTO ADICIONAL)

MATRIZ DE PESOS DE ATENCIÓN (θ)



Escala de colores: ROJO (Fuerte Positivo) -> BLANCO (Cero) -> AZUL (Fuerte Negativo)

Los pesos base reflejan las relaciones generales aprendidas en el pre-entrenamiento.

ENTRADA: "El banco..." MODELO BASE

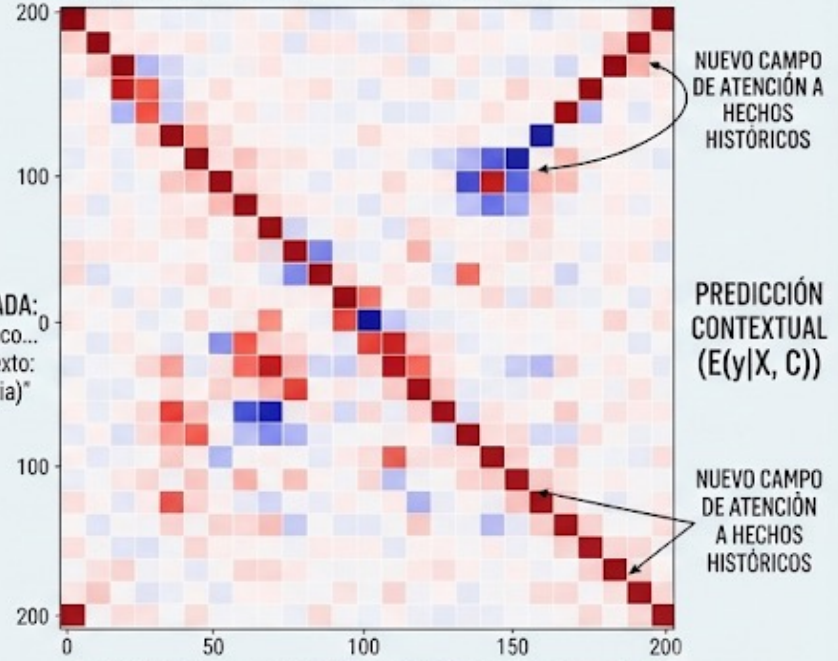
CONTEXTO ADICIONAL (kNN/Atención)

→ MODIFICACIÓN DINÁMICA DE PESOS

2. PESOS MODIFICADOS (CON CONTEXTO ADICIONAL)

MATRIZ DE PESOS DE ATENCIÓN MODIFICADOS (θ')

ENTRADA: "El banco... (Contexto: Historia)"



MATRIZ DE PESOS DE ATENCIÓN MODIFICADOS (θ')

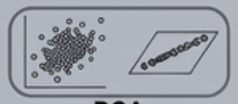
Los pesos se reajustan en tiempo real para priorizar o ignorar información basada en el contexto específico proporcionado (ej. 'Contexto: Historia').

El Mapa de la Inteligencia Artificial: De los Algoritmos Clásicos a la Era Generativa

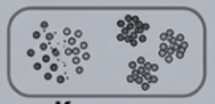
Paradigma Principal: Aprendizaje Clásico

APRENDIZAJE NO SUPERVISADO

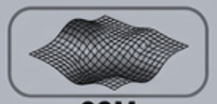
Explora Patrones Ocultos



PCA
Dimension Reduction



K-means
Clustering



SOM
Self-Organizing Maps

Buscan patrones ocultos sin etiquetas, simplifican dimensiones y agrupan datos.

APRENDIZAJE SUPERVISADO

Usa Datos Etiquetados



GLM
Modelos Lineales



KNN
Vecinos Cercanos



SVM
Máquinas de Soporte



Boost
Gradient Boosting

Aprenden de ejemplos con etiquetes para clasificar o predecir resultados.

Evolución a Redes Neuronales y Aprendizaje Profundo

ANN
Redes Neuronales Artificiales





DNN
Redes Profundas

Evolución de redes simples a múltiples capas para procesar información compleja.

Arquitecturas Especializadas

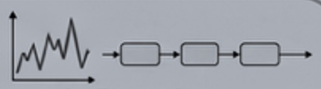
CNN



Visión por Computadora



LSTM



Secuencias Temporales

U-Net





Segmentación de Imágenes

Arquitecturas diseñadas para tipos de datos especificos como imágenes y secuencias.

Revolución de los Transformers y IA Generativa





LLM
Modelos de Lenguaje Masivos

GPT
Generative Pre-trained Transformer

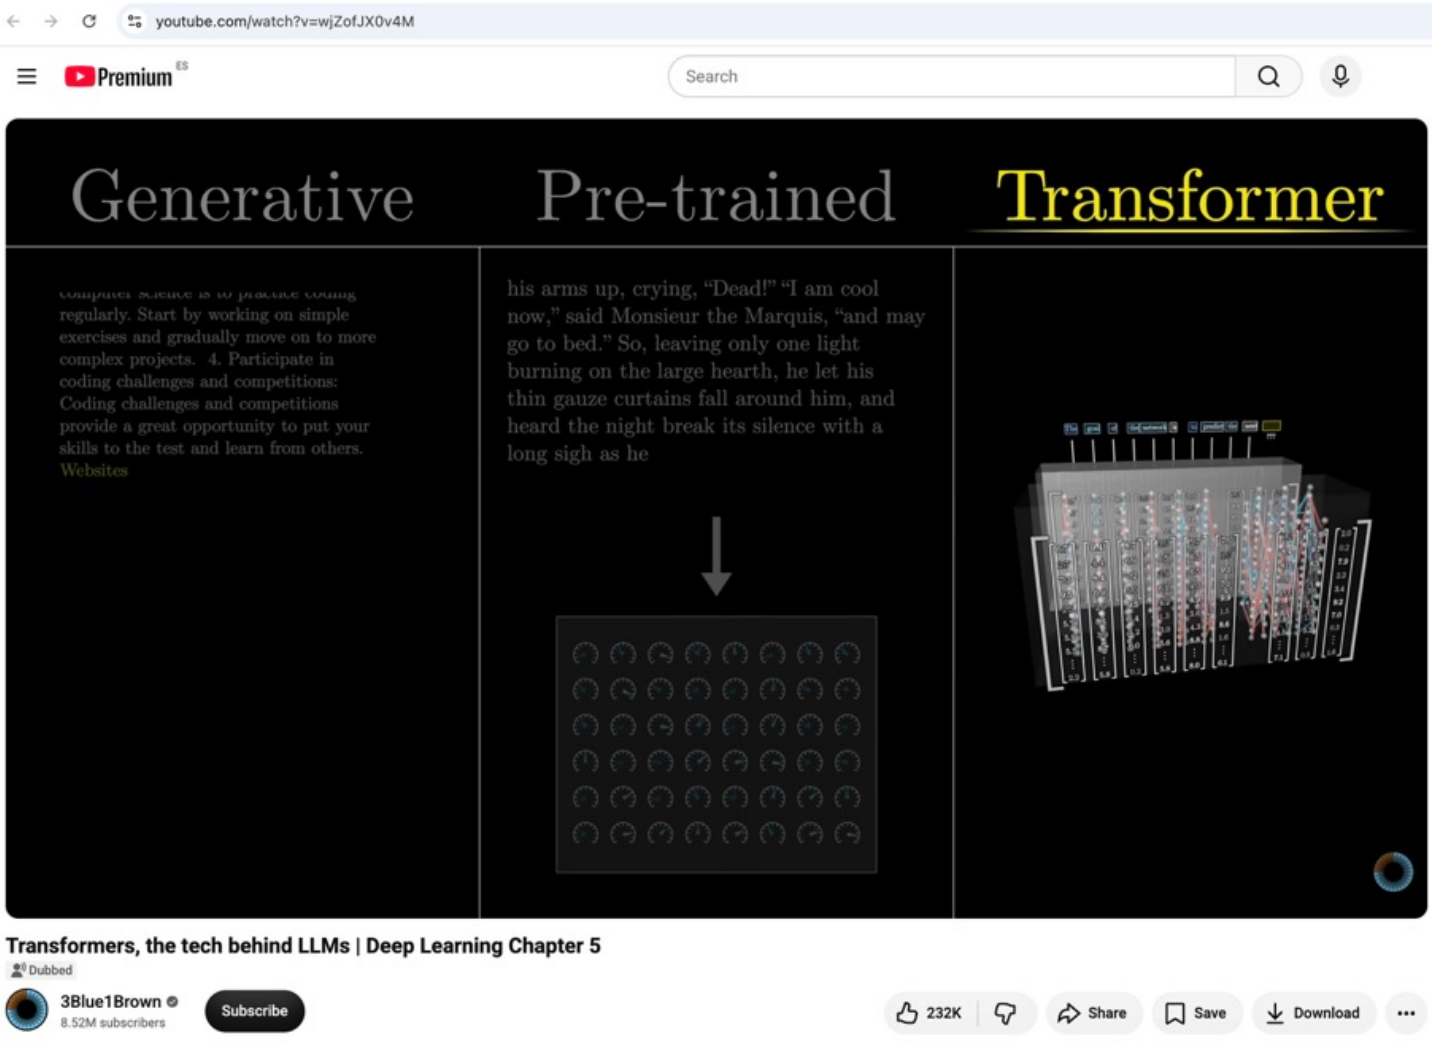




El procesamiento paralelo del Transformer impulsa modelos generativos capaces de crear contenido y comprender lenguaje a gran escala.

NotebookL

https://www.youtube.com/watch?v=wjZofJX0v4M



0:00 – 3:20

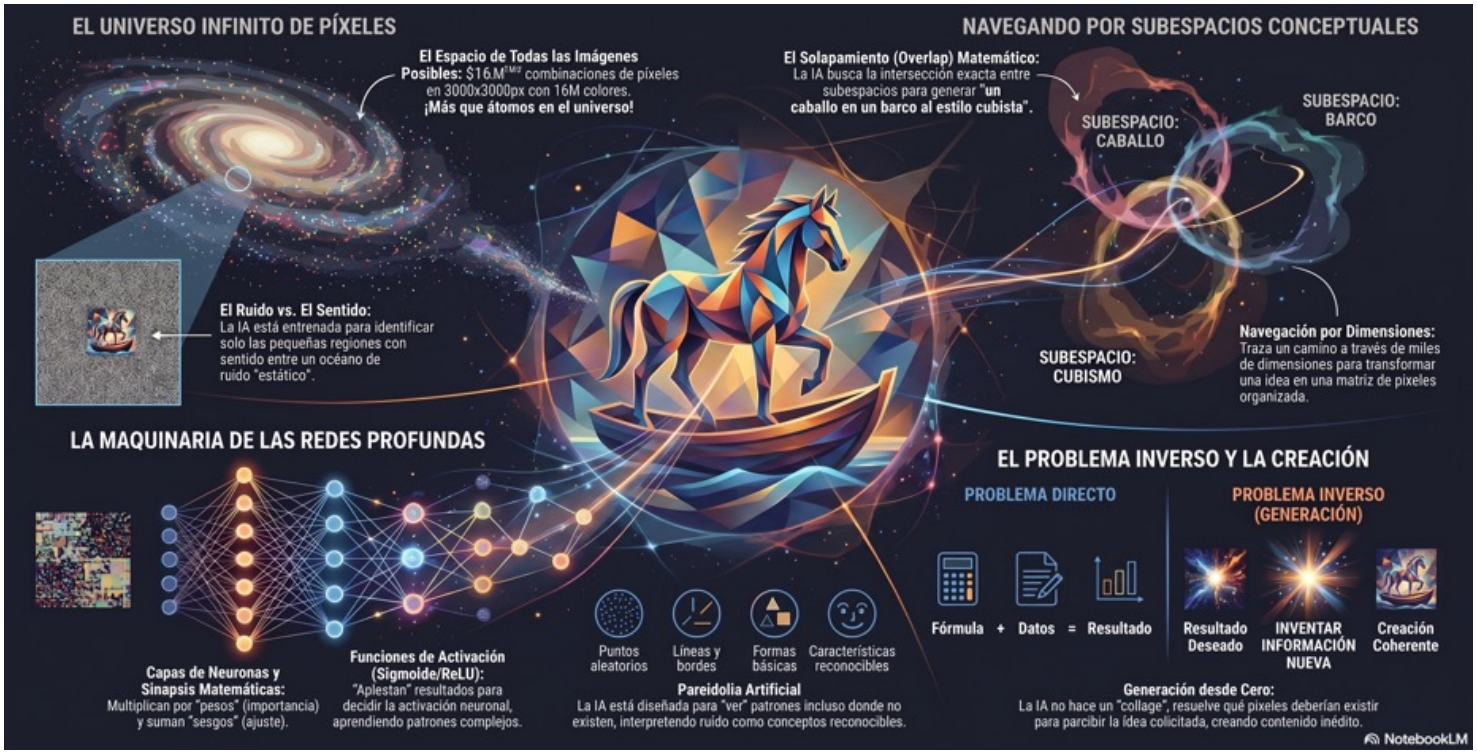
12:26 – 18:20

IAs generativas de imágenes

Jaime Altozano
3.54M subscribers

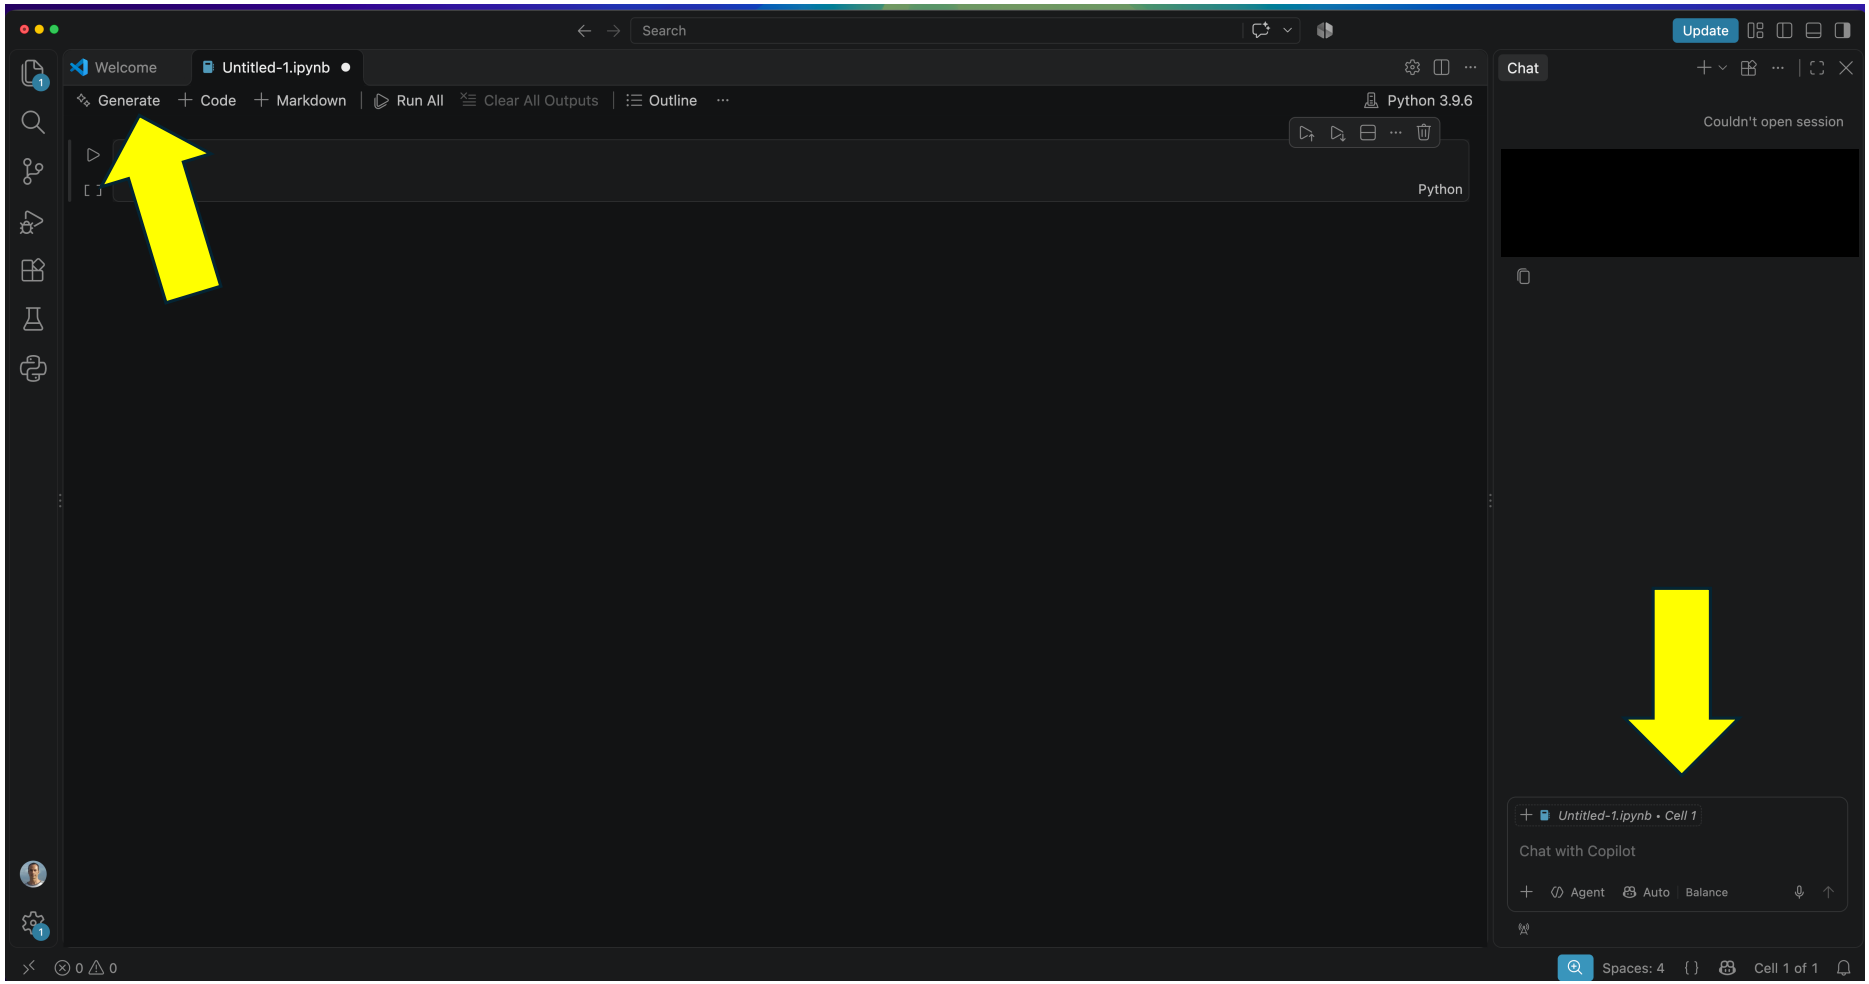
Prompt: “Haz una imagen de un caballo en un barco al estilo cubista”

https://www.youtube.com/watch?v=3eMmmj3roOs
(25:41)




¿Que vamos a usar las próximas 5 sesiones?

VS Code + Python + Superpowers (GitHub Copilot)



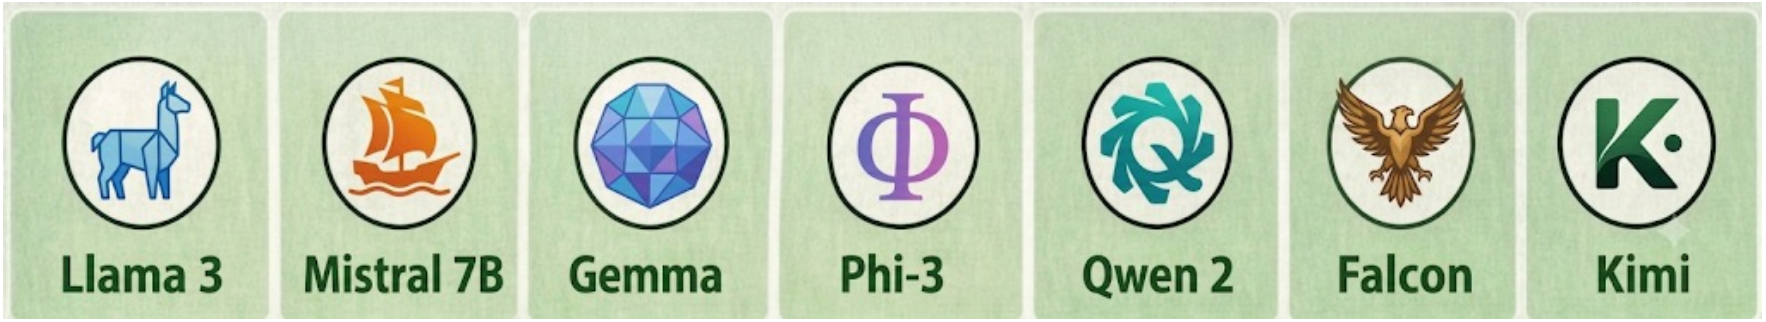

¿Que IA tengo que usar?

IAs comerciales



- Libres vs Suscripción (20 euros/mes) / Copilot es gratis en UC
- Grandes Modelos – Mucho recurso computacional – GPUs (>500.000 millones par.)
- Acceso a Internet necesario

IAs libres / locales



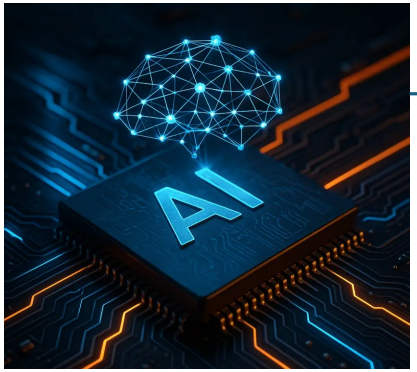
- Libres
- Modelos Pequeños-Medianos – Menor recurso computacional GPU (<200.000 millones par.)
- No es necesario acceso a Internet
- PC o portatil – 8 o 16 Gb RAM - solo funcionarán estas IAs con modelos pequeños (Llama 3.2 (3B), Phi-4 Mini (3.8B) y Qwen 2.5 (3B o 7B cuantizado))

21/08/2026



Componente	Requisito Mínimo (Ajustado)	Rendimiento Óptimo 🚀
Tarjeta Gráfica (NVIDIA)	RTX 4070 / RTX 5060 Ti (con cortes en contexto)	**RTX 4080 / 5080 / 4090 (16 GB VRAM)**
Procesador Apple Silicon	M3/M4/M5 Pro (Con mínimo 36 GB RAM)	**M3 / M4 / M5 Max (48 GB o 64 GB RAM)**
Memoria RAM del PC	32 GB RAM	**64 GB RAM**
Software de ejecución	LM Studio o Llama.cpp (usando cuantización Q4_K_M)	LM Studio con GPU Offload al 100%

Model	LLM Stats	License	Coding	Parameters (B)
GPT-5.6 Sol	57.4	Closed	50.6	-
Claude Opus 5	56.3	Closed	42.7	-
Claude Fable 5	56.1	Closed	48.8	-
Claude Mythos Preview UNRELEASED	56.0	Closed	46.7	-
Kimi K3	54.9	Open	45.9	2800
GLM-5.3 NEW	54.7	Open	45.4	753
DeepSeek-V4-Pro-0813 NEW	54.2	Open	43.3	1600
Qwen3.8 Max	53.3	Open	42.3	2400
GPT-5.6 Terra	52.9	Closed	46.3	-
Claude Opus 4.8	51.9	Closed	43.9	-
Muse Spark 1.1	51.8	Closed	37.9	-
Gemini 3.7 Flash NEW	51.2	Closed	38.6	-
Claude Sonnet 5	49.6	Closed	40.1	-
GPT-5.5	49.3	Closed	41.2	-
Grok 4.5	47.5	Closed	39.4	-
DeepSeek-V4-Flash-0731	47.4	Open	37.4	304
Grok 4.6 NEW	47.3	Closed	39.7	-
Seed 2.1 Pro	47.3	Closed	36.6	-
GLM-5.2	46.9	Open	38.6	753
Qwen3.8-27B NEW	46.9	Open	35.3	27.8
GPT-5.6 Luna	46.6	Closed	39.9	-
Qwen3.7 Max	46.4	Closed	38.6	-
Claude Opus 4.6	45.7	Closed	34.9	-
GPT-5.5 Pro	45.5	Closed	–	-



Ollama

opencode

Open Notebook

Open Design

HTML

PDF

PDF

DOCX

README

quarto

jupyter

python™

FreeCAD

QGIS


Si queréis ser autodidactas...

SECOND EDITION

LEARN AI-Assisted Python Programming

With GitHub Copilot and ChatGPT

Leo Porter • Daniel Zingaro

Foreword by Beth Simon



MANNING

VS Code + Python + Superpowers (GitHub Copilot)

